



Politechnika Warszawska

Wydział Matematyki
i Nauk Informatycznych

Praca dyplomowa licencjacka

na kierunku Matematyka i Analiza Danych

Konstrukcja miary na przestrzeni funkcji ciągłych na przestrzeniach metrycznych i jej zastosowanie jako apriori w estymacji bayesowskiej.

Krzysztof Michalak

Numer albumu 333 076

promotor
dr Krzysztof Rudaś

WARSZAWA 2026

Streszczenie

Konstrukcja miary na przestrzeni funkcji ciągłych na przestrzeniach metrycznych i jej zastosowanie jako apriori w estymacji bayesowskiej.

Praca dotyczy problemu wnioskowania statystycznego o rozkładach prawdopodobieństwa opisanych na przestrzeniach metrycznych. Praca wyprowadza model bayesowski, którego rozkład *a priori* jest wyznaczany za pomocą procesu stochastycznego. Zamiast heurystycznego doboru procesu, zostaje on wyprowadzony w pracy z naturalnych aksjomatów na niego narzuconych, opartych o własności metryki przestrzeni.

W części teoretycznej wprowadzamy oraz uzasadniamy aksjomaty oraz wykorzystując teorię procesów Lévy’ego, reprezentację Lévy’ego–Chinczyna, własności przestrzeni L^1 -zanurzalnych oraz twierdzenie Kołmogorowa–Chentsova, przeprowadzamy dowód który jednoznacznie wyznaczy nam ten proces. Udowodniliśmy, że jedynym procesem spełniającym te założenia jest proces gaussowski o ściśle zdefiniowanej kowariancji zależnej od odległości metrycznej.

W części praktycznej przeprowadzamy eksperyment na danych rzeczywistych dla naszego modelu. Porównujemy zaproponowany model z innymi podejściami dotyczącymi tej dziedziny, a następnie przedstawiamy wyniki dla nich uzyskane. W pracy wykazaliśmy, że model wyprowadzony za pomocą zaproponowanych aksjomatów zachowuje się wysoką skutecznością w warunkach małej liczby obserwacji ($N \leq 10^3$).

Słowa kluczowe: statystyka nieparametryczna, wnioskowanie bayesowskie, procesy gaussowskie, przestrzenie L^1 -zanurzalne, gęstość prawdopodobieństwa.

Abstract

Construction of a measure on the space of continuous functions on metric spaces and its application as a prior in Bayesian estimation.

This work addresses the problem of statistical inference for probability distributions defined on metric spaces. The paper derives a Bayesian model whose *a priori* distribution is determined using a stochastic process. Instead of a heuristic selection of the process, it is derived in this work from natural axioms imposed on it, based on the metric properties of the space.

In the theoretical part, we introduce and justify the axioms and, utilizing the theory of Lévy processes, the Lévy–Khintchine representation, the properties of L^1 -embeddable spaces, and the Kolmogorov–Chentsov theorem, we conduct a proof that uniquely determines this process. We have proven that the only process satisfying these assumptions is a Gaussian process with a strictly defined covariance dependent on the metric distance.

In the practical part, we conduct an experiment on real data for our model. We compare the proposed model with other approaches in this field, and then present the obtained results. In this work, we have demonstrated that the model derived using the proposed axioms exhibits high efficacy under conditions of a small number of observations ($N \leq 10^3$).

Keywords: nonparametric statistics, Bayesian inference, Gaussian processes, L^1 -embeddable spaces, probability density.

Spis treści

Streszczenie	2
Abstract	3
1 Wstęp	7
1.1 Istota problemu i wyzwania analityczne	7
1.2 Historia wnioskowania przestrzennego	7
1.3 Cel pracy	8
1.4 Struktura pracy	8
2 Definicje i oznaczenia wstępne	10
2.1 Modelowanie bayesowskie w przestrzeniach funkcyjnych	10
2.1.1 Proces stochastyczny jako miara probabilistyczna na przestrzeni funkcyjnej	13
2.1.2 Aktualizacja bayesowska na przestrzeni funkcyjnej	14
2.2 Procesy gaussowskie	15
2.3 Geometria metryki i przestrzenie L^1 -zanurzalne	16
3 Wprowadzenie i uzasadnienie aksjomatów	18
3.1 Metryka jako jedyny nośnik informacji	18
3.2 Krytyka modelowania na poziomie gęstości f	18
3.3 Reprezentacja logarytmiczna i identyfikowalność	19
3.4 Rozwiązanie problemów modelowania bezpośredniego	20
3.5 Aksjomaty rozkładu przyrostów i ich uzasadnienie	20
4 Teoretyczne wyznaczenie rozkładu <i>a priori</i>	22
4.1 Normalność brzegowa przyrostów	22
4.2 Izometryczne zanurzanie w prostopadłościach w L^1	24
4.3 Niezależność lub identyczność przyrostów na bokach hiper-równoległocianu w L^1	26
4.4 Twierdzenie (o gaussowskości procesu)	28
4.5 Istnienie i własności procesu gaussowskiego	29
4.6 Parowa estymacja parametru skali oraz algorytmiczny potok obliczeniowy .	33
4.6.1 Ogólna procedura parowej estymacji parametru skali c	33

4.6.2	Ogólny algorytm	34
5	Teoretyczne przygotowanie eksperymentu	35
5.1	Założenia dotyczące danych testowych	35
5.2	Dane AquaMaps i ich zgodność z założeniami	35
5.3	Konieczność wstępnego przetwarzania	36
5.4	L^1 -zanurzalność metryki Haversine’a	36
5.5	Projekt eksperymentu i metryki oceny	38
6	Przeprowadzenie eksperymentu i wyniki	39
6.1	Implementacja numeryczna modelu autorskiego	39
6.1.1	Geometria jako jedyne źródło informacji a priori	39
6.1.2	Numeryczna poprawność macierzy kowariancji	39
6.1.3	Wnioskowanie a posteriori	40
6.1.4	Optymalizacje wydajnościowe procedury numerycznej	40
6.2	Przygotowanie danych	40
6.3	Opis modeli referencyjnych	41
6.3.1	Model wygładzania przestrzennego (Bayesian Spatial Smoothing)	41
6.3.2	Model Dirichleta (Non-Spatial Baseline)	41
6.3.3	Model logistyczno-normalny Lenka	42
6.3.4	Przestrzenne modele sprzężone (Conjugate Spatial Models)	42
6.4	Procedury eksperymentalne i ewaluacja	43
6.4.1	Testy	43
6.4.2	Scenariusz I: Pojedynczy test porównawczy	43
6.4.3	Scenariusz II: Wpływ liczności próby	44
6.4.4	Statystyczna weryfikacja istotności: test Nemenyi	47
6.5	Omówienie wyników i wnioski	47
7	Podsumowanie	48
7.1	Dalsze drogi rozwoju	48
7.1.1	Uogólniony parametr gładkości i relaksacja niezależności przyrostów	49
7.1.2	Adaptacyjna metryka przestrzeni i modelowanie anizotropii	49
	Bibliografia	51
	Wykaz symboli i skrótów	53

Spis rysunków	55
Spis tabel	56

1 Wstęp

1.1 Istota problemu i wyzwania analityczne

Statystyczne wnioskowanie o rozkładach prawdopodobieństwa, które są opisane na przestrzeniach metrycznych, jest ważnym i nadal rozwijającym się działem statystyki nieparametrycznej. Znajduje ono zastosowanie w wielu działach nauki, takich jak np. geostatystyka czy też analiza środowiskowa. W tej pracy opieramy się na modelu bayesowskim. Chcemy połączyć rozkład *a priori*, czyli probabilistykę z geometrią przestrzeni metrycznej. W ten sposób jak wyznaczymy rozkład za pomocą metryki to model bayesowski pozwoli nam na aktualizację prawdopodobieństwa na podstawie zaobserwowanej próbki pochodzącej z prawdziwej gęstości.

Wielu matematyków poświęcało się badaniom wnioskowania statystycznego na przestrzeniach metrycznych, co świadczy o jego znaczeniu. Wkład w rozwój w tym zakresie wnieśli m.in. Andriej Prochorow [1] (który wprowadził słabą zbieżność miar), Patrick Billingsley [2] (procesy stochastyczne w przestrzeniach metrycznych), Michel Talagrand [3] (ciągłość pól losowych) oraz Richard Dudley [4] (entropia metryczna).

Mimo tego estymacja rozkładów na przestrzeniach metrycznych nadal stanowi wyzwanie. Zadanie to jest trudniejsze niż zwykła estymacja skończonego wektora parametrów, gdyż wymaga odtworzenia całego, nieskończeniowymiarowego rozkładu prawdopodobieństwa. Ponadto często nie można założyć np. istnienia pochodnych poszukiwanej funkcji gęstości. Ograniczenie założeń jedynie do ciągłości jest więc sposobem na ogólne podejście do problemu.

1.2 Historia wnioskowania przestrzennego

W latach 50. XX wieku Dani Krige [5] wprowadził koncepcję wag estymacyjnych zależnych od odległości w szacowaniu złóż. Od tej pracy zaczął się rozwój wnioskowania przestrzennego. Następnie w latach 60. Georges Matheron [6] sformalizował te intuicje w ramach teorii geostatystyki, gdyż wprowadził on pojęcie wariogramu oraz zmiennej zregionalizowanej. W latach 80. Noel Cressie oraz Julian Besag [7] rozwinęli teorię markowskich pól losowych (*Markov Random Fields*). To następnie doprowadziło w latach 90. do powstania nurtu *Model-Based Geostatistics* (zaproponowanego przez Petera Diggle'a [8]), który z powodzeniem zintegrował wnioskowanie przestrzenne z modelowaniem bayesowskim.

Jednym z popularnych podejść do nieparametrycznej bayesowskiej estymacji gęstości jest podejście oparte na pracy Petera J. Lenka z 1988 roku „*The logistic normal distribution for Bayesian, nonparametric, predictive densities*” [9]. Lenk stworzył model, w którym ukryte pole gaussowskie przekształcane jest na przestrzeń funkcji gęstości za pomocą transformacji logistycznej (operatora *softmax*). W naszej pracy jego model będzie odniesieniem w kontekście statystyki nieparametrycznej. Jednak w przeciwieństwie do jego pracy będziemy wyprowadzali funkcję kowariancji procesu gaussowskiego bezpośrednio z

aksjomatów, które nałożymy na przestrzeń metryczną.

Początkowo model ten posiadał wiele problemów obliczeniowych, które zostały rozwiązane dzięki takim narzędziom jak log-gaussowskie procesy Coxa [10] czy też zoptymalizowane techniki wnioskowania przybliżonego (m.in. algorytmy INLA [11] i podejście SPDE [12]).

1.3 Cel pracy

Celem tej pracy jest porzucenie heurystycznego dobierania funkcji kowariancji na rzecz podejścia aksjomatycznego - nakładania aksjomatów na sposób zachowywania się rozkładu na przestrzeni metrycznej, a następnie wyprowadzania z nich funkcji kowariancji.

Będziemy modelować więc rozkład procesem stochastycznym, jednak zamiast zakładać określoną strukturę zależności przestrzennej tego procesu, w pracy zakładamy naturalne aksjomaty dotyczące przyrostów log-gęstości względem metryki przestrzeni. Wykorzystując klasyczne twierdzenie Paula Lévy'ego [13] oraz silne własności geometryczne struktur wielowymiarowych, udowodnimy, że jedynym procesem stochastycznym spełniającym te założenia geometryczne jest proces gaussowski o ściśle zdefiniowanej kowariancji opartej na odległości. Tak wyznaczony rozkład *a priori* zostanie następnie zintegrowany z mechaniką transformacji logistycznej Lenka oraz algorytmami MCMC, co pozwoli na stworzenie kompletnego modelu wnioskowania bayesowskiego.

Kluczowym osiągnięciem tego podejścia będzie całkowite oparcie modelu na wybranej metryce (która będzie musiała być z założenia L^1 -zanurzalna), gdyż bez zewnętrznej wiedzy eksperckiej, w problemach geostatystycznych odległość i fakt ciągłości funkcji rozkładu gęstości względem niej jest naszą podstawową wiedzą. Wyprowadzimy więc schemat, w jakim odległość i owe założenie ciągłości staną się dla nas źródłem informacji *a priori*.

1.4 Struktura pracy

Praca jest zbudowana w następujący sposób:

W **rozdziale 2** wprowadzono pojęcia jak model bayesowski, procesy stochastyczne, procesy gaussowskie czy metryki L^1 -zanurzalne, stanowiące podstawy do zrozumienia pracy.

W **rozdziale 3** pokazano, dlaczego modelowanie funkcji logarytmu przyrostów jest łatwiejsze niż bezpośrednie modelowanie rozkładu, oraz zdefiniowano aksjomaty dotyczące procesu, którym będziemy ją modelować.

Rozdział 4 prezentuje dowód matematyczny pracy. Udowadniamy w nim, że przy założonych aksjomatach jedynym procesem spełniającym nasze założenia jest proces gaussowski o konkretnej funkcji kowariancji (z dokładnością co do stałej).

Rozdział 5 stanowi teoretyczną podstawę eksperymentu. Formułuje założenia dotyczące danych testowych, zgodność wybranych danych testowych z założeniami i formułuje teoretyczny projekt eksperymentu.

Rozdział 6 opisuje implementację modelu i eksperymentu oraz przedstawia i opisuje

uzyskane wyniki.

Całość zamyka **rozdział 7**, w którym zebrano wnioski oraz zaproponowano dalsze drogi rozwoju.

2 Definicje i oznaczenia wstępne

W tym rozdziale wprowadzimy podstawowe pojęcia teoretyczne, które będą niezbędne do zrozumienia dalszej części pracy.

2.1 Modelowanie bayesowskie w przestrzeniach funkcyjnych

Wnioskowanie bayesowskie to metoda statystyczna opierająca się na twierdzeniu Bayesa. Definiuje ono w jaki sposób obserwacje zmieniają nam prawdopodobieństwo wcześniej przyjęte jako rozkład *a priori*. Obiektem estymowanym w klasycznym parametrycznym modelu Bayesowskim jest skończenie wymiarowy wektor θ , będący parametrem rozkładu. Ten parametr jednoznacznie wyznacza nam rozkład prawdopodobieństwa obserwacji $\mathbf{X}$. Rozkład *a posteriori* wyraża się wtedy za pomocą relacji prawdopodobieństwa warunkowego.

Twierdzenie 2.1 (Twierdzenie Bayesa). *Niech θ będzie nieznanym parametrem rozkładu, a $\mathbf{X}$ zbiorem zaobserwowanych danych. Rozkład prawdopodobieństwa θ pod warunkiem zaobserwowanych danych $\mathbf{X}$ (rozkład *a posteriori*) wyraża się wzorem:*

$$p(\theta | \mathbf{X}) = \frac{p(\mathbf{X} | \theta)\pi(\theta)}{p(\mathbf{X})} = \frac{p(\mathbf{X} | \theta)\pi(\theta)}{\int_{\Theta} p(\mathbf{X} | \theta') \pi(\theta') d\theta'}, \quad (1)$$

gdzie $p(\mathbf{X} | \theta)$ jest funkcją wiarygodności (*likelihood*), $\pi(\theta)$ jest rozkładem *a priori* (*prior*), natomiast $p(\mathbf{X}) = \int_{\Theta} p(\mathbf{X} | \theta') \pi(\theta') d\theta'$ jest stałą normalizującą (*marginal likelihood*).

Dowód. Z definicji prawdopodobieństwa warunkowego rozkładu łącznego wektora obserwacji $\mathbf{X}$ oraz parametru θ mamy:

$$p(\mathbf{X}, \theta) = p(\theta | \mathbf{X})p(\mathbf{X})$$

$$p(\mathbf{X}, \theta) = p(\mathbf{X} | \theta)\pi(\theta).$$

Przyrównując do siebie prawe strony obu równań, otrzymujemy:

$$p(\theta | \mathbf{X})p(\mathbf{X}) = p(\mathbf{X} | \theta)\pi(\theta).$$

Dzieląc obustronnie przez $p(\mathbf{X})$ (przy założeniu, że prawdopodobieństwo brzegowe danych $p(\mathbf{X}) > 0$), otrzymujemy pierwszą część tezy:

$$p(\theta | \mathbf{X}) = \frac{p(\mathbf{X} | \theta)\pi(\theta)}{p(\mathbf{X})}.$$

Aby wyznaczyć stałą $p(\mathbf{X})$, całkujemy rozkład łączny po całej przestrzeni parametrów Θ :

$$p(\mathbf{X}) = \int_{\Theta} p(\mathbf{X}, \theta') d\theta' = \int_{\Theta} p(\mathbf{X} | \theta') \pi(\theta') d\theta'.$$

Podstawiając to do mianownika, uzyskujemy ostateczną postać wzoru. $\square$

W niniejszej pracy nie będziemy estymować skończonego wektora θ , lecz całą nieznaną funkcję gęstości f . Twierdzenie Bayesa przyjmie więc postać następującą:

Twierdzenie 2.2 (Twierdzenie Bayesa dla przestrzeni funkcyjnych). *Niech $f \in \mathcal{F}$ będzie nieznaną funkcją gęstości, a $\mathbf{X}$ zbiorem obserwacji. Rozkład prawdopodobieństwa funkcji f pod warunkiem zaobserwowanych danych $\mathbf{X}$ (rozkład a posteriori) wyraża się formalnym wzorem:*

$$p(f | \mathbf{X}) \equiv \frac{d\mathbb{P}(\cdot | \mathbf{X})}{dP}(f) = \frac{p(\mathbf{X} | f)}{\int_{\mathcal{F}} p(\mathbf{X} | f') dP(f')}, \quad (2)$$

gdzie $p(\mathbf{X} | f)$ jest funkcją wiarygodności (co w tym ujęciu oznacza bezpośrednią ewaluację funkcji gęstości na danych, czyli w przypadku warunkowo niezależnych obserwacji $p(\mathbf{X} | f) = \prod_{i=1}^n f(X_i)$), a P jest miarą probabilistyczną a priori na przestrzeni $\mathcal{F}$.

Dowód. Niech P będzie miarą probabilistyczną a priori na przestrzeni funkcyjnej $\mathcal{F}$ i niech $\mathbf{X}$ będą naszymi obserwacjami.

Zgodnie z definicją, rozkład zmiennej f oraz obserwacji $\mathbf{X}$ dla dowolnych mierzalnych zbiorów $A \subset \mathcal{F}$ oraz $B \subset \mathcal{X}$ wyraża wzorem:

$$\mathbb{P}(f \in A, \mathbf{X} \in B) = \int_A \left(\int_B p(\mathbf{x} | f) d\mathbf{x} \right) dP(f). \quad (3)$$

Z drugiej strony, ten sam rozkład łączny musi dać się wyrazić klasycznie, korzystając z szukanego rozkładu a posteriori i rozkładu brzegowego danych $p(\mathbf{x})$:

$$\mathbb{P}(f \in A, \mathbf{X} \in B) = \int_B \mathbb{P}(f \in A | \mathbf{X} = \mathbf{x}) p(\mathbf{x}) d\mathbf{x}, \quad (4)$$

gdzie gęstość brzegowa danych wynosi $p(\mathbf{x}) = \int_{\mathcal{F}} p(\mathbf{x} | f') dP(f')$.

Na mocy twierdzenia Tonellego-Fubinię o zmianie kolejności całkowania, w pierwszym równaniu możemy zmienić kolejność całkowania:

$$\mathbb{P}(f \in A, \mathbf{X} \in B) = \int_B \left(\int_A p(\mathbf{x} | f) dP(f) \right) d\mathbf{x}. \quad (5)$$

Przyrównując do siebie prawe strony Równania 4 i 5, widzimy, że zachodzą one dla dowolnego mierzalnego zbioru B . To oznacza, że funkcje podcałkowe (względem $d\mathbf{x}$) muszą być sobie równe prawie wszędzie. Otrzymujemy zatem:

$$\mathbb{P}(f \in A | \mathbf{X} = \mathbf{x}) p(\mathbf{x}) = \int_A p(\mathbf{x} | f) dP(f). \quad (6)$$

Zakładając, że $p(\mathbf{x}) > 0$, możemy podzielić równanie obustronnie, uzyskując jawną postać prawdopodobieństwa warunkowego dla dowolnego zbioru funkcji A :

$$\mathbb{P}(f \in A | \mathbf{X} = \mathbf{x}) = \int_A \frac{p(\mathbf{x} | f)}{p(\mathbf{x})} dP(f). \quad (7)$$

Powyższe równanie ostatecznie dowodzi, że nowa miara *a posteriori* posiada względem miary *a priori* P gęstość (pochodną Radona-Nikodyma) równą dokładnie funkcji podcałkowej. Zapisując tę gęstość w przyjętej notacji bayesowskiej, otrzymujemy tezę twierdzenia:

$$p(f | \mathbf{X}) \equiv \frac{d\mathbb{P}(\cdot | \mathbf{X})}{dP}(f) = \frac{p(\mathbf{X} | f)}{p(\mathbf{X})} = \frac{p(\mathbf{X} | f)}{\int_{\mathcal{F}} p(\mathbf{X} | f') dP(f')}. \quad (8)$$

□

Definicja 2.1 (Model bayesowski). Modelem bayesowskim nazywamy układ $(\mathcal{F}, p(\mathbf{X} | f), P)$, gdzie $\mathcal{F}$ jest przestrzenią funkcyjną, $p(\mathbf{X} | f)$ reprezentuje funkcję wiarygodności, a $P(f)$ miarę probabilistyczną (*prior*).

Głównym wyzwaniem w modelach nieparametrycznych pozostaje poprawne zdefiniowanie miary *a priori* P na przestrzeni nieskończenie wymiarowej, względem której całkujemy. Aby poprawnie zdefiniować rozkład prawdopodobieństwa na przestrzeni funkcji, powszechnie wykorzystuje się procesy stochastyczne.

Definicja 2.2 (Proces stochastyczny). Niech $(\Omega, \mathcal{F}, \mathbb{P})$ będzie przestrzenią probabilistyczną, a $(S, \mathcal{B})$ przestrzenią mierzalną. Niech T będzie dowolnym zbiorem niepustym. Jeżeli dla każdego $t \in T$, odwzorowanie $X_t : (\Omega, \mathcal{F}) \rightarrow (S, \mathcal{B})$ jest zmienną losową, to rodzinę $(X_t)_{t \in T}$ nazywamy procesem stochastycznym.

Definicja 2.3 (Trajektoria procesu stochastycznego). Dla ustalonego zdarzenia elementarnego $\omega \in \Omega$, odwzorowanie:

$$t \mapsto X_t(\omega)$$

określone na zbiorze indeksów T o wartościach w przestrzeni stanów S , nazywamy trajektorią (lub realizacją, ścieżką) procesu stochastycznego.

W ujęciu przestrzeni indeksów, oraz oznaczając zmienną losową przypisaną do konkretnego punktu jako $g(t) = X_t$, wartość $g(t)$ nie jest z góry ustaloną liczbą, lecz zmienną losową scharakteryzowaną przez określony rozkład. $X_t(\omega)$ będziemy więc oznaczać jako $g(x, \omega)$. Wprowadzamy taką notację, ponieważ gęstość w poszczególnych punktach przestrzeni metrycznej będziemy interpretować jako proces stochastyczny.

Aby na podstawie rozkładów skończonych wywnioskować o istnieniu procesu powszechnie stosuje się twierdzenie Kołmogorowa.

Definicja 2.4 (Warunki zgodności Kołmogorowa). Rodzina wielowymiarowych dystrybuant rozkładów łącznych $\{F_{X_{t_1}, \dots, X_{t_n}}\}$ dla wszystkich skończonych podzbiorów indeksów $\{t_1, \dots, t_n\} \subset T$ spełnia warunki zgodności Kołmogorowa, jeżeli dla każdej permutacji $\sigma \in S_n$ (rodzina permutacji $\{1, \dots, n\}$) oraz dowolnego n zachodzą następujące relacje:

1. Niezmienniczość względem permutacji:

$$F_{X_{t_{\sigma(1)}}, \dots, X_{t_{\sigma(n)}}}(x_{\sigma(1)}, \dots, x_{\sigma(n)}) = F_{X_{t_1}, \dots, X_{t_n}}(x_1, \dots, x_n).$$

2. Spójność brzegowa:

$$\lim_{x_n \rightarrow \infty} F_{X_{t_1}, \dots, X_{t_n}}(x_1, \dots, x_{n-1}, x_n) = F_{X_{t_1}, \dots, X_{t_{n-1}}}(x_1, \dots, x_{n-1}).$$

Twierdzenie 2.3 (Twierdzenie Kołmogorowa o istnieniu procesu). *Jeżeli rodzina skończenie wymiarowych rozkładów $\{F_{X_{t_1}, \dots, X_{t_n}}\}$ zdefiniowana na przestrzeni T spełnia warunki zgodności Kołmogorowa, to istnieje dokładnie jeden proces stochastyczny $\{g(t) : t \in T\}$ (w sensie rozkładów skończenie wymiarowych), którego rozkłady łączne odpowiadają tej rodzinie.*

Dowód można znaleźć w pracy Billingsleya [14] w rozdziale 7 w sekcji 36.

Należy jednak w pełni zrozumieć, w jaki sposób aparat ten wyznacza miarę *a priori* na przestrzeni funkcji i dlaczego tak dobrze integruje się z wnioskowaniem bayesowskim.

2.1.1 Proces stochastyczny jako miara probabilistyczna na przestrzeni funkcyjnej

Niech $(\Omega, \mathcal{A}, \mathbb{P})$ będzie ustaloną przestrzenią probabilistyczną, a T dowolnym zbiorem. Rozważmy przestrzeń wszystkich funkcji $\mathcal{F} = \{f : T \rightarrow \mathbb{R}\}$. Następnie zdefiniujemy zdarzenie, polegające na tym, że funkcja w punkcie t przyjmuje wartość z zadanego przedziału (a, b) :

$$U_{t,a,b} = \{f \in \mathcal{F} : f(t) \in (a, b)\}. \quad (9)$$

Zakładamy, że dysponujemy procesem stochastycznym $\{X_t : t \in T\}$. Zatem każdemu zdarzeniu $U_{t,a,b}$ odpowiada mierzalne zdarzenie w przestrzeni bazowej Ω , opisane przez proces stochastyczny. Ustanawiamy między nimi bezpośrednie, strukturalne przypisanie:

$$f(t) \in (a, b) \iff X_t \in (a, b). \quad (10)$$

Pełne σ -ciało $\mathcal{B}(\mathcal{F})$ na przestrzeni funkcji powstaje poprzez wielokrotne stosowanie przeliczalnych operacji (sum, przecięć i dopełnień) na tych właśnie zdarzeniach bazowych $U_{t,a,b}$.

Skoro mamy ustalone bezpośrednie przypisanie dla elementarnych zdarzeń mierzalnych, to dla każdego, dowolnie złożonego zdarzenia $B \in \mathcal{B}(\mathcal{F})$ możemy jednoznacznie skonstruować jego odpowiednik w σ -ciele $\mathcal{A}$. Konstrukcja ta polega na tym, że w definicji zdarzenia B podmieniamy każde wystąpienie warunku $f(t) \in (a, b)$ na odpowiadające mu zdarzenie $X_t \in (a, b)$, pozostawiając całą strukturę operacji mnogościowych bez zmian.

Ponieważ $\mathcal{A}$ jest pełnoprawnym σ -ciałem (zamkniętym na te same przeliczalne operacje), gwarantuje nam to, że ów odpowiednik jest prawidłowym, mierzalnym zdarzeniem dla procesu stochastycznego. Prawdopodobieństwo jakiegokolwiek zdarzenia B na przestrzeni funkcyjnej definiujemy zatem globalnie jako prawdopodobieństwo jego odpowiednika:

$$P(B) := \mathbb{P}(\text{zdarzenie w } \Omega \text{ powstałe przez zamianę } f(t) \text{ na } X_t). \quad (11)$$

Takie ujęcie sprawia, że $P(B)$ faktycznie spełnia warunki miary probabilistycznej $\mathbb{P}$ (takie jak np. σ -addytywność). W konkretnym przypadku, gdy definiujemy zdarzenie składające

się z warunków narzuconych na dowolną (skończoną lub przeliczalnie nieskończoną) rodzinę punktów indeksowaną zbiorem $I \subset \mathbb{N}$, relacja ta przyjmuje jawną postać:

$$P \left(\bigcap_{i \in I} \{f(t_i) \in A_i\} \right) = \mathbb{P} \left(\bigcap_{i \in I} \{X_{t_i} \in A_i\} \right). \quad (12)$$

Tym samym istnienie procesu stochastycznego jest równoznaczne ze spójnym zdefiniowaniem rozkładu *a priori* na całej, nieskończenie wymiarowej przestrzeni funkcyjnej.

2.1.2 Aktualizacja bayesowska na przestrzeni funkcyjnej

Mając zdefiniowaną miarę *a priori* P na przestrzeni funkcyjnej $\mathcal{F}$, rozważmy problem wnioskowania o nieznaną funkcję gęstości f na podstawie zaobserwowanych danych. Zakładamy, że dysponujemy zbiorem niezależnych obserwacji $\mathbf{X} = (X_1, \dots, X_n)$, wylosowanych z rozkładu o gęstości f . W tym przypadku funkcja wiarygodności jest iloczynem wartości szukanej funkcji gęstości w punktach obserwacji:

$$L(f) = \prod_{k=1}^n f(X_k). \quad (13)$$

Chcemy wyznaczyć miarę *a posteriori* dla dowolnego, ogólnego zdarzenia w przestrzeni funkcyjnej. Rozważmy zdarzenie B polegające na spełnieniu przeliczalnej (lub skończonej) liczby warunków w punktach testowych t_i :

$$B = \bigcap_{i \in I} \{f(t_i) \in A_i\}. \quad (14)$$

Ponieważ wartości funkcji w punktach obserwacyjnych $\mathbf{X}$ jednoznacznie wyznaczają wiarygodność, włączamy je bezpośrednio w strukturę naszego zdarzenia. Skoro szukana funkcja musi w tych punktach przyjmować jakiejkolwiek wartości rzeczywiste, zdarzenie B możemy równoważnie zapisać poszerzając je o zbiór warunków dla punktów z próby:

$$B = \bigcap_{i \in I} \{f(t_i) \in A_i\} \cap \bigcap_{k=1}^n \{f(X_k) \in \mathbb{R}\}. \quad (15)$$

Takie ujęcie pozwala nam przeprowadzić aktualizację prawdopodobieństwa dowolnego zbioru B poprzez bezpośrednie przemnożenie miary *a priori* przez funkcję wiarygodności, bez zakładania istnienia jakichkolwiek gęstości w sensie Lebesgue'a.

Twierdzenie 2.4 (Bayesowska aktualizacja miary na $\mathcal{F}$ dla funkcji gęstości). *Dla dowolnego zdarzenia $B \in \mathcal{B}(\mathcal{F})$, jego miara *a posteriori* $P(B \mid \mathbf{X})$ jest definiowana przez całkowanie funkcji wiarygodności na obszarze zbioru B bezpośrednio względem miary *a priori* P :*

$$P(B \mid \mathbf{X}) = \frac{\int_B \left(\prod_{k=1}^n f(X_k) \right) dP(f)}{\int_{\mathcal{F}} \left(\prod_{k=1}^n f(X_k) \right) dP(f)}. \quad (16)$$

W przypadku gdy wnioskujemy o zachowaniu funkcji w skończonej liczbie punktów $(t_1, \dots, t_m)$, całka ta redukuje się do całkowania względem skończonego wymiarowego rozkładu (miary indukowanej) procesu:

$$P(f(t_1) \in A_1, \dots, f(t_m) \in A_m \mid \mathbf{X}) = \frac{\int_{A_1 \times \dots \times A_m \times \mathbb{R}^n} (\prod_{k=1}^n u_k) dP_{t_1 \dots t_m, X_1 \dots X_n}(v_1, \dots, v_m, u_1, \dots, u_n)}{\int_{\mathbb{R}^n} (\prod_{k=1}^n u'_k) dP_{X_1 \dots X_n}(u'_1, \dots, u'_n)}, \quad (17)$$

gdzie $dP_{t_1 \dots t_m, X_1 \dots X_n}$ oraz $dP_{X_1 \dots X_n}$ oznaczają odpowiednio łączne, skończone wymiarowe miary a priori ewaluacji funkcji w połączonym zbiorze punktów.

Dowód. Teza wynika bezpośrednio z definicji miary a posteriori jako całki z jej gęstości (pochodnej Radona-Nikodyma udowodnionej w twierdzeniu 2) względem miary bazowej P , gdzie $p(\mathbf{X} \mid f) = \prod_{k=1}^n f(X_k)$. $\square$

2.2 Procesy gaussowskie

W dalszej części pracy pojawi się pojęcie procesów gaussowskich. Są one jedną z najważniejszych i najlepiej zbadanych rodzin w teorii procesów stochastycznych i stanowią fundamentalną strukturę w nieparametrycznym modelowaniu przestrzennym. Znajomość podstaw teorii tych procesów jest zatem kluczowa dla zrozumienia części dowodowej pracy.

Definicja 2.5 (Miara gaussowska). Miarę μ_G na $\mathcal{B}(\mathbb{R}^d)$ nazywamy miarą gaussowską (rozkładem gaussowskim), jeśli istnieje macierz deterministyczna $A \in \mathbb{R}^{d \times m}$ oraz wektor $a \in \mathbb{R}^d$, takie że miara ta jest rozkładem prawdopodobieństwa pewnego d -wymiarowego wektora losowego X (tzn. $\mu_G = \mu_X$), dla którego zachodzi:

$$X \stackrel{d}{=} AY + a,$$

gdzie $\stackrel{d}{=}$ oznacza równość według rozkładu, $Y \sim \mathcal{N}(0, I_m)$ jest m -wymiarowym wektorem losowym o standardowym rozkładzie normalnym, a I_m oznacza macierz jednostkową wymiaru m .

Klasyczny wielowymiarowy rozkład normalny zazwyczaj definiuje się przez wzór na gęstość, co wymaga odwracalnej (nieosobliwej) macierzy kowariancji. Natomiast miara gaussowska, zdefiniowana poprzez przekształcenie $X \stackrel{d}{=} AY + a$, to pojęcie szersze, które zachowuje pełną poprawność matematyczną nawet dla zdegenerowanych rozkładów pozbawionych gęstości.

Definicja 2.6 (Proces gaussowski). Niech $S \neq \emptyset$. Proces stochastyczny $\{g(x) \equiv X_x\}_{x \in S}$ nazywamy gaussowskim, jeśli wszystkie jego rozkłady skończonego wymiaru są gaussowskie.

Struktura procesu gaussowskiego $\{g(x) : x \in S\}$ jest w pełni zdeterminowana przez:

- **Funkcję średniej:** $m(x) = \mathbb{E}[g(x)]$,

- **Funkcję kowariancji:** $K(x, y) = \text{Cov}(g(x), g(y))$.

W związku z tym po wykazaniu, że dany proces należy do rodziny rozkładów gaussowskich, jednoznaczne określenie procesu sprowadza się do wyznaczenia funkcji średniej oraz kowariancji. Funkcja kowariancji musi jednak spełniać warunek nieujemnej określoności:

Definicja 2.7 (Funkcja nieujemnie określona). Funkcję symetryczną $K : S \times S \rightarrow \mathbb{R}$ nazywamy nieujemnie określoną, jeżeli dla każdego skończonego układu punktów $\{x_1, \dots, x_n\} \subset S$ oraz dowolnych wag $\{c_1, \dots, c_n\} \subset \mathbb{R}$ zachodzi:

$$\sum_{i=1}^n \sum_{j=1}^n c_i c_j K(x_i, x_j) \geq 0. \quad (18)$$

Istnienie procesu gaussowskiego o zadanych parametrach gwarantuje poniższe twierdzenie:

Twierdzenie 2.5 (O istnieniu procesu gaussowskiego). *Dla dowolnej funkcji $m : S \rightarrow \mathbb{R}$ oraz dowolnej funkcji $K : S \times S \rightarrow \mathbb{R}$, która jest symetryczna i nieujemnie określona, istnieje proces gaussowski $\{g(x) : x \in S\}$ o średniej m i funkcji kowariancji K .*

Dowód tego twierdzenia znajduje się między innymi w pracy Kallenberg [15] w rozdziale 11.

2.3 Geometria metryki i przestrzenie L^1 -zanurzalne

Wyprowadzenie procesu dla pełnej rodziny metryk jest bardzo trudne z powodu nieujemnej określoności funkcji kowariancji. Z tego powodu w niniejszej pracy ograniczymy się do klasy przestrzeni metrycznych L^1 -zanurzalnych. Z geometrycznego punktu widzenia oznacza to, że odległość między dowolnymi wierzchołkami skończonej podprzestrzeni reprezentuje tzw. metrykę cięcia.

Definicja 2.8 (Przestrzeń L^1 i norma L^1). Przestrzenią $L^1(\mathbb{R}^d)$ nazywamy przestrzeń $\mathbb{R}^d$ wyposażoną w normę :

$$\|\mathbf{x} - \mathbf{y}\|_1 = \sum_{k=1}^d |x_k - y_k|. \quad (19)$$

Definicja 2.9 (Metryka cięcia). Dla dowolnego niepustego podzbioru $J \subset S$, metrykę cięcia $\delta_J(x, y)$ definiujemy jako:

$$\delta_J(x, y) = \begin{cases} 1 & \text{jeżeli } |\{x, y\} \cap J| = 1, \\ 0 & \text{w przeciwnym razie.} \end{cases} \quad (20)$$

Definicja 2.10 (Metryka i przestrzeń L^1 -zanurzalna). Przestrzeń metryczną (S, d) nazywamy L^1 -zanurzalną, jeżeli dla każdego skończonego podzbioru punktów $X \subset S$, odległość $d(x, y)$ na tym podzbiorze stanowi kombinację stożkową metryk cięcia, tzn. istnieją nieujemne wagi $a_J \geq 0$, dla których zachodzi:

$$d(x, y) = \sum_{\emptyset \neq J \subset X} a_J \delta_J(x, y), \quad \forall x, y \in X. \quad (21)$$

Ograniczenie się do tej rodziny przestrzeni pozwala nam na rzutowanie dowolnej skończonej konfiguracji punktów do przestrzeni wielowymiarowej z metryką L^1 . Własność ta wymusza na metryce własność ujemnego typu oraz kryterium Schoenberga.

Definicja 2.11 (Przestrzeń typu ujemnego według Schoenberga). Przestrzeń metryczną (S, d) nazywamy przestrzenią o typie ujemnym (lub spełniającą warunek Schoenberga), jeżeli dla dowolnego skończonego układu punktów $\{x_0, x_1, \dots, x_n\} \subset S$ oraz dowolnych rzeczywistych wag $a_0, a_1, \dots, a_n$ sumujących się do zera ($\sum_{i=0}^n a_i = 0$) zachodzi nierówność:

$$\sum_{i=0}^n \sum_{j=0}^n a_i a_j d(x_i, x_j) \leq 0. \quad (22)$$

Przestrzeń L^1 (a więc również L^1 -zanurzalne) spełniają warunek Schoenberga co udowodnił w pracy Isaac J. Schoenberg [16] (rozdział 3) Założenie to pomoże nam w Sekcji 4.5.

Definicja 2.12 (Wymiar przestrzeni metrycznej). Przestrzeń metryczna (S, d) ma **skończony wymiar metryczny** D , jeżeli dla każdego $r > 0$ i $\epsilon \in (0, r)$, każdą kulę o promieniu r można pokryć co najwyżej $(C \cdot r/\epsilon)^D$ kulami o promieniu ϵ , gdzie $C > 0$ jest stałą niezależną od promienia. W całej pracy zakładamy, że $D < \infty$, co jest warunkiem koniecznym do stosowania twierdzenia Kołmogorowa–Chentsova w dowodzie ciągłości trajektorii (patrz Rozdział 4).

3 Wprowadzenie i uzasadnienie aksjomatów

W tym rozdziale podejmiemy próbę sformułowania aksjomatów pozwalających na wyznaczenie ogólnego rozkładu *a priori* na przestrzeni funkcji gęstości $f(x)$, zakładając, że jedyną informacją, jaką się dysponuje, jest L^1 -zanurzalna przestrzeń metryczna (S, d) o skończonym wymiarze metrycznym $D < \infty$ wyposażona w miarę μ oraz założenie o ciągłości f względem d (gdzie funkcja gęstości f jest wyznaczana względem miary μ). Dzięki tym aksjomatom będziemy w stanie w Rozdziale 4 wyznaczyć rozkład *a priori* i zamknąć cały model bayesowski.

3.1 Metryka jako jedyny nośnik informacji

Przyjmujemy, że metryka d , która jest L^1 -zanurzalna, stanowi jedyny nośnik informacji *a priori* o zależnościach między wartościami funkcji gęstości w punktach. W związku z tym rozkład prawdopodobieństwa powinien zależeć wyłącznie od dystansu metrycznego. Chcemy więc zbudować ogólny model bayesowski, który opierając się jedynie na metryce d i aksjomatach, które założymy, pozwoli wyznaczyć rozkład *a priori*, z którego potem będzie można wnioskować zgodnie z prawem Bayesa. Najpierw jednak zauważmy, że z pewnych powodów modelowanie bezpośrednie jest utrudnione.

3.2 Krytyka modelowania na poziomie gęstości f

Zauważmy, że nałożenie aksjomatów bezpośrednio na funkcję gęstości f jest trudne z dwóch powodów. Pierwszym z nich jest fakt, że gęstość musi spełniać warunek unormowania $\int_S f(u) d\mu(u) = 1$. Sprawia to, że nie możemy lokalnie zmieniać wartości f w jednym punkcie, gdyż to od razu wymusi zmianę na pozostałych punktach. Co więcej, wartości rozkładu zmieniają się w zależności od wielkości rozważanej przestrzeni, co znacząco utrudnia formułowanie spójnych aksjomatów.

Weźmy na przykład modelowanie gęstości występowania rzadkiego minerału na obszarze 100 km^2 . Jeśli w jednym punkcie, w wyniku nowej obserwacji, zwiększymy wartość gęstości, to aby zachować wartość całki równą 1, musimy automatycznie obniżyć wartości we wszystkich pozostałych punktach obszaru, nawet tych oddalonych o dziesiątki kilometrów. Taka wymuszona korelacja ma charakter czysto matematyczny i nie wynika z fizycznych właściwości badanego zjawiska.

Drugim problemem z modelowaniem bezpośrednim jest problem skali relatywnej. W przypadku funkcji gęstości kluczową zmianą jest zmiana procentowa (relatywna), a nie bezwzględna. Zauważmy, że intuicyjnie punkt o gęstości 0.1 jest „bliżej” wartości 0.2 niż wartości 0. Odległość bezwzględna między oboma tymi przypadkami jest równa, jednak w skali relatywnej przejście od 0.1 do 0 oznacza całkowity zanik możliwości wystąpienia obserwacji, czyli nieskończony spadek szansy. Warto jeszcze dodać, że chcielibyśmy, aby wartości ujemne były nieskończenie odległe od wartości dodatnich, gdyż funkcja gęstości

ich nie przyjmuje. W skali bezwzględnej wartości ujemne to założenie nie jest spełnione (0.1 nie jest nieskończenie odległe od -0.1 , a jedynie o 0.2).

Rozpatrzmy kolejny przykład. Rozważając dwa punkty x_1 oraz x_2 w pewnej małej przestrzeni S_1 , dla których gęstości wynoszą odpowiednio $f(x_1) = 0.6$ i $f(x_2) = 0.4$. Różnica bezwzględna między nimi to 0.2 . Jeśli następnie rozszerzymy przestrzeń o nowe punkty i ze względu na warunek unormowania wartości te zostaną przeskalowane w dół – na przykład do poziomów $f'(x_1) = 0.06$ i $f'(x_2) = 0.04$, to w takiej sytuacji różnica bezwzględna wynosi już tylko 0.02 , mimo że relacja (stosunek prawdopodobieństw) między tymi dwoma punktami w ogóle nie uległa zmianie. Dowodzi to jednoznacznie, że różnica bezwzględna na poziomie f nie jest dobrą metryką do oceny „wielkości” zmiany.

3.3 Reprezentacja logarytmiczna i identyfikowalność

Zauważmy, że do pełnego i jednoznacznego wyznaczenia gęstości $f(x)$ wystarczy poprawne określenie przyrostów procesu g_{x_0} dla dowolnego $x_0 \in S$. Przyjmijmy definicję:

$$g_{x_0}(x) = \ln f(x) - \ln f(x_0). \quad (23)$$

Przekształcając powyższe równanie, otrzymujemy:

$$\frac{f(x)}{f(x_0)} = \exp(g_{x_0}(x)). \quad (24)$$

Wykorzystując to, że $(\int_S f(u) d\mu(u) = 1)$, możemy wyznaczyć $f(x_0)$:

$$\int_S \frac{f(u)}{f(x_0)} d\mu(u) = \frac{1}{f(x_0)} \int_S f(u) d\mu(u) = \frac{1}{f(x_0)}. \quad (25)$$

Stąd wynika, że wartość gęstości w punkcie referencyjnym jest w pełni zdeterminowana przez całkę z eksponenty przyrostów:

$$f(x_0) = \frac{1}{\int_S \exp(g_{x_0}(u)) d\mu(u)}. \quad (26)$$

Ostatecznie, podstawiając wyznaczone $f(x_0)$ do wzoru na $f(x)$, otrzymujemy:

$$f(x) = \frac{\exp(g_{x_0}(x))}{\int_S \exp(g_{x_0}(u)) d\mu(u)}. \quad (27)$$

Zatem proces przyrostów logarytmu gęstości jednoznacznie wyznacza nam funkcję gęstości f . Możemy zatem zamiast bezpośredniego modelowania modelować proces przyrostów g_{x_0} .

Podsumowując, mamy zatem przestrzeń metryczną z miarą (S, d, μ) . (Przestrzeń S to dziedzina, na której operujemy, d to metryka jednoznacznie wyznaczająca odległości między punktami, a μ to miara bazowa umożliwiająca całkowanie). Na tej przestrzeni mamy szukaną funkcję gęstości prawdopodobieństwa f (nie jest ona ustalona, lecz jest zmienną losową). Ponadto zakładamy, że funkcja f jest ciągła względem d . Oraz mamy również proces $g_{x_0}(x) = \ln f(x) - \ln f(x_0)$. On również musi być ciągły względem μ i jednoznacznie wyznacza nam naszą szukaną zmienną f . Będziemy więc estymować proces g_{x_0} , a z niego otrzymamy naszą szukaną funkcję f .

3.4 Rozwiązanie problemów modelowania bezpośredniego

Zauważmy, że wprowadzenie procesu $g_{x_0}(x)$ rozwiązuje nasze trudności związane z modelowaniem bezpośrednim na funkcji gęstości $f(x)$. Po pierwsze, modelując proces g_{x_0} , nie jesteśmy ograniczeni całą na całej przestrzeni, a jedynie wymogiem wartości procesu w punkcie x_0 ($g_{x_0}(x_0) = 0$). Wartość procesu w punkcie nie wpływa na zależności między przyrostami, dzięki czemu możliwe jest np. założenie istnienia niezależnych przyrostów na rozłącznych w sensie metrycznym odcinkach przestrzeni.

Po drugie, przejście na różnice logarytmów zamienia nam skalę bezwzględną na skalę logarytmiczną (relatywną). W przestrzeni logarytmicznej różnica wartości odpowiada dokładnie logarytmowi ilorazu prawdopodobieństw:

$$g_{x_0}(x) - g_{x_0}(y) = \ln f(x) - \ln f(y) = \ln \left(\frac{f(x)}{f(y)} \right).$$

To gwarantuje nam, że przyrosty stają się niezależne od skali globalnej. Poszerzenie obszaru badań sprawia, że bezwzględne wartości gęstości ulegają proporcjonalnemu przeskalowaniu w dół, co dotyczy również ich różnicy bezwzględnej. Natomiast różnica logarytmiczna (reprezentująca stosunek szans) pozostanie nienaruszona. Co więcej, spadek gęstości do zera i wartości ujemnych (całkowity zanik możliwości wystąpienia obserwacji) jest poprawnie odwzorowywany jako spadek wartości procesu do $-\infty$, co wiernie oddaje nieskończony charakter takiej zmiany na skali relatywnej.

3.5 Aksjomaty rozkładu przyrostów i ich uzasadnienie

Na proces g_{x_0} nakładamy trzy aksjomaty. Ich sformułowanie nie jest arbitralnym wyborem matematycznym, lecz wynika bezpośrednio z dążenia do konstrukcji rozkładu *a priori* opierającego się jedynie na znajomości metryki L^1 -zanurzalnej, przy założeniu zachowania ciągłości f względem niej.

Aksjomat 1. - addytywności geometrycznej i niezależności. Jeżeli dla skończonego układu punktów $x_0, x_1, \dots, x_n \in S$:

$$\sum_{i=1}^n d(x_{i-1}, x_i) = d(x_0, x_n), \quad (28)$$

to ciąg przyrostów $g_{x_0}(x_1) - g_{x_0}(x_0), g_{x_0}(x_2) - g_{x_0}(x_1), \dots, g_{x_0}(x_n) - g_{x_0}(x_{n-1})$ stanowi układ zmiennych losowych wzajemnie niezależnych.

Uzasadnienie: Jest to próba realizacji założenia braku informacji poza ciągłością. Skoro nie zakładamy różniczkowalności ani żadnych wyższych gładkości procesu g_{x_0} , to wiedza o zmianie „szansy” na odcinku xy nie powinna dawać żadnej informacji o zmianie na odcinku yz , o ile są one rozłączne w sensie ścieżki addytywnej. Każde inne założenie wprowadzałoby zależność, która nie wynika z samej ciągłości na metryce d .

Aksjomat 2. - ciągłości ścieżek. Proces g_{x_0} posiada wersję o ciągłych trajektoriach z prawdopodobieństwem 1, tzn. istnieje zdarzenie Ω_0 o prawdopodobieństwie $\mathbb{P}(\Omega_0) = 1$ takie, że dla każdego $\omega \in \Omega_0$ funkcja $x \mapsto g_{x_0}(x, \omega)$ jest ciągła na S .

Uzasadnienie: Jest to bezpośrednia konsekwencja założenia początkowego. Skoro estymujemy funkcję f , o której wiemy, że jest ciągła względem d , to proces $g_{x_0}(x) = \ln f(x) + C$ też musi być ciągły, ponieważ logarytm i dodawanie zachowują ciągłość.

Aksjomat 3. - lokalności i spójności rozkładów skończone wymiarowych. Dla dowolnego skończonego układu par punktów $(x_1, x_2), (x_3, x_4), \dots, (x_{2n-1}, x_{2n})$ należących do przestrzeni S , rozkład łączny wektora przyrostów

$$\Delta = [g_{x_0}(x_1) - g_{x_0}(x_2), g_{x_0}(x_3) - g_{x_0}(x_4), \dots, g_{x_0}(x_{2n-1}) - g_{x_0}(x_{2n})]^T \quad (29)$$

jest funkcją wyłącznie wartości metryki $d(x_i, x_j)$ dla wszystkich par $i, j \in \{1, \dots, 2n\}$. Rozkład ten pozostaje niezmienniczy względem rozszerzania przestrzeni S o dodatkowe punkty, co oznacza, że dla dowolnej innej przestrzeni L^1 -zanurzalnej S' zawierającej punkty o identycznych wzajemnych odległościach, rozkład wektora Δ jest taki sam. Własność ta czyni proces g globalnym obiektem geometrycznym, którego parametrem jest L^1 -zanurzalna przestrzeń metryczna i którego zachowanie zależy wyłącznie od metryki, a nie od konkretnej realizacji przestrzeni.

Uzasadnienie: Skoro zgodnie z przyjętym założeniem dekompozycja odległości w przestrzeni L^1 -zanurzalnej jest jedynym nośnikiem informacji o relacjach przestrzennych, to wspólna struktura probabilistyczna dowolnego układu punktów musi być zdeterminowana wyłącznie przez ich wzajemne odległości. Oznacza to, że informacja płynąca z samego faktu istnienia innych punktów w przestrzeni S jest zerowa, co pozwala na obiektywne konstruowanie rozkładu *a priori* bez wprowadzania nieuzasadnionych korelacji globalnych. Każdy układ punktów tworzy „autonomiczną” strukturę geometryczną, której opis probabilistyczny jest samowystarczalny.

Ponadto zauważmy, że procesy g_{x_0} i g_{x_1} różnią się jedynie o stałą:

$$g_{x_0}(x) - g_{x_1}(x) = \ln f(x) - \ln f(x_0) - (\ln f(x) - \ln f(x_1)) = \ln f(x_0) - \ln f(x_1) = C \quad (30)$$

Można więc zauważyć, że powyższe aksjomaty zachowują się tak samo niezależnie od punktu referencyjnego x_0 , ponieważ operują na przyrostach, więc stała C nie ma znaczenia (dla każdego x, y : $g_{x_0}(x) - g_{x_0}(y) = g_{x_1}(x) + C - g_{x_1}(y) - C = g_{x_1}(x) - g_{x_1}(y)$). Dlatego w dalszej części zamiast pisać g_{x_0} , będziemy po prostu pisać g .

4 Teoretyczne wyznaczenie rozkładu *a priori*

W tej części wyznaczymy rozkład *a priori*, który domknie nam cały model bayesowski. Zakładamy aksjomaty 1), 2), 3). Chcielibyśmy się dowiedzieć, jak w takim razie musi wyglądać rozkład procesu $g(x)$. Okazuje się, że musi on być jednoznacznie wyznaczonym procesem gaussowskim o konkretnej kowariancji (z dokładnością do stałej c), co udowodnimy w tej sekcji.

Dowód tego twierdzenia zostanie przedstawiony na końcu tego rozdziału, ponieważ najpierw musimy zdefiniować i udowodnić kilka lematów.

4.1 Normalność brzegowa przyrostów

W pierwszej części dowodu będziemy chcieli pokazać, że przyrosty brzegowe muszą być normalne. Formułując pierwszy lemat, będziemy korzystać z teorii procesów Lévy'ego. Zanim jednak do tego przejdziemy, musimy zbudować odpowiedni aparat pojęciowy, zaczynając od podstawowego pojęcia, jakim jest własność nieskończonej podzielności.

Definicja 4.1 (Nieskończona podzielność). Zmienną losową X nazywamy *nieskończenie podzielną*, jeżeli dla każdego $n \in \mathbb{N}$ można ją przedstawić jako sumę n niezależnych zmiennych losowych o identycznym rozkładzie: $X \stackrel{d}{=} X_1 + \dots + X_n$.

Powyższa własność jest kluczowa, ponieważ pozwala na rozbięcie X na sumę dowolnie małych, niezależnych zmiennych losowych. Aby jednak w pełni scharakteryzować rozkład takich zmiennych, musimy wprowadzić pojęcie miary Lévy'ego.

Definicja 4.2 (Miara Lévy'ego). Miarą Lévy'ego na prostej rzeczywistej nazywamy miarę Borela ν zdefiniowaną na $\mathbb{R} \setminus \{0\}$, która spełnia warunek całkowy:

$$\int_{\mathbb{R} \setminus \{0\}} \min(1, u^2) \nu(du) < \infty. \quad (31)$$

Formalny warunek całkowy zdefiniowany powyżej został pierwotnie sformułowany przez Paula Lévy'ego [13].

Mając zdefiniowaną tę miarę (która opisuje wielkość i intensywność skoków) możemy sformułować podstawowe twierdzenie, które całkowicie determinuje postać funkcji charakterystycznej dla każdej zmiennej nieskończenie podzielnej. Wzór ten łączy deterministyczny dryf, ciągłą część gaussowską oraz część skokową.

Twierdzenie 4.1 (Reprezentacja Lévy'ego-Chinczyna [17]). *Logarytm funkcji charakterystycznej $\psi(t) = \ln \mathbb{E}[e^{itX}]$ zmiennej nieskończenie podzielnej dopuszcza reprezentację:*

$$\psi(t) = it\gamma - \frac{1}{2}\sigma^2 t^2 + \int_{\mathbb{R} \setminus \{0\}} (e^{itu} - 1 - itu\mathbf{1}_{|u|<1}) \nu(du), \quad (32)$$

gdzie ν jest miarą Lévy'ego opisującą intensywność i wielkość skoków procesu.

(Dowód w pracy [17] w rozdziale 2 (tw. 8.1).)

Dotychczas rozpatrywaliśmy pojedynczą zmienną losową. Koncepcja nieskończonej podzielności w naturalny sposób rozszerza się jednak na procesy stochastyczne ewoluujące w czasie (lub, jak w naszym przypadku, w przestrzeni metrycznej). Jeżeli nasz proces spełnia warunki niezależności i stacjonarności przyrostów, otrzymamy szeroką klasę procesów Lévy’ego.

Definicja 4.3 (Proces Lévy’ego). Niech $(\Omega, \mathcal{F}, \mathbb{P})$ będzie przestrzenią probabilistyczną. Proces stochastyczny $\{L_t\}_{t \geq 0}$ o wartościach w $\mathbb{R}$ nazywamy **procesem Lévy’ego**, jeżeli spełnia następujące warunki:

1. $L_0 = 0$ prawie na pewno.
2. **Niezależność przyrostów:** Dla dowolnych $0 \leq t_1 < t_2 < \dots < t_n$ zmienne losowe $L_{t_1}, L_{t_2} - L_{t_1}, \dots, L_{t_n} - L_{t_{n-1}}$ są niezależne.
3. **Stacjonarność przyrostów:** Dla dowolnych $s, t \geq 0$ rozkład $L_{t+s} - L_t$ zależy wyłącznie od s (nie od t).
4. **Ciągłość stochastyczna:** Dla każdego $\varepsilon > 0, t \geq 0, \lim_{h \rightarrow 0} \mathbb{P}(|L_{t+h} - L_t| > \varepsilon) = 0$.

Dla takich procesów można zastosować taką samą reprezentację Lévy’ego-Chinczyna, co dla pojedynczej zmiennej losowej.

Twierdzenie 4.2 (Reprezentacja Lévy’ego-Chinczyna dla procesów Lévy’ego [17]). *Dla każdego procesu Lévy’ego $\{L_t\}_{t \geq 0}$ istnieją: stała $\gamma \in \mathbb{R}$ (dryf), $\sigma^2 \geq 0$ (wariancja części gaussowskiej) oraz miara ν na $\mathbb{R} \setminus \{0\}$ (miara skoków Lévy’ego) spełniająca $\int_{\mathbb{R} \setminus \{0\}} \min(1, u^2) \nu(du) < \infty$, takie że funkcja charakterystyczna L_t ma postać:*

$$\mathbb{E}[e^{i\theta L_t}] = \exp\left(t\left[i\gamma\theta - \frac{1}{2}\sigma^2\theta^2 + \int_{\mathbb{R} \setminus \{0\}} (e^{i\theta u} - 1 - i\theta u \mathbf{1}_{|u|<1}) \nu(du)\right]\right).$$

(Dowód w pracy [17] w rozdziale 4 (tw. 19.2)).

Wróćmy do naszego problemu znajdowania postaci procesu g . Zgodnie z aksjomatem 3, rozkład przyrostu $g(x) - g(y)$ zależy **wyłącznie** od odległości $d(x, y)$. Kluczową konsekwencją tego założenia, wzmocnioną przez koncepcję uniwersalności procesu g dla klasy przestrzeni L^1 -zanurzalnych, jest fakt, iż proces ten możemy analizować na prostej rzeczywistej $(\mathbb{R}, |\cdot|)$, która jest przestrzenią L^1 -zanurzalną. Rozkład przyrostu między punktami na prostej odległymi o d będzie taki sam, jak rozkład przyrostu w oryginalnej przestrzeni S między punktami odległymi o d . Wszystkie wnioski wyciągnięte na prostej będą zatem, przez aksjomat 3, natychmiast obowiązywały w S .

Lemat 4.1 (o brzegowej normalności i liniowości wariancji). *Przy założeniu, że (S, d) jest L^1 -zanurzalna i ma skończony wymiar metryczny, jeżeli g spełnia aksjomaty 1, 2 oraz 3, to dla dowolnych $x, y \in S$ rozkład brzegowy*

$$g(x) - g(y) \sim \mathcal{N}(0, c \cdot d(x, y)),$$

gdzie $c \in \mathbb{R}_+$ jest stałą niezależną od wyboru punktów.

Dowód. Ustalmy $x, y \in S$ i niech $d = d(x, y)$. Na mocy przytoczonej powyżej zasady uniwersalności procesu g oraz aksjomatu 3, rozkład przyrostu $g(d) - g(0)$ na prostej $(\mathbb{R}, |\cdot|)$ jest identyczny z rozkładem $g(x) - g(y)$ w oryginalnej przestrzeni S :

$$g(d) - g(0) \stackrel{d}{=} g(x) - g(y). \quad (33)$$

Wystarczy zatem wyznaczyć rozkład przyrostu na prostej, a wynik automatycznie przeniesie się na dowolną parę punktów w S .

Rozpatrujemy proces g wyłącznie na prostej $(\mathbb{R}, |\cdot|)$. Dla dowolnych $0 \leq t_0 < t_1 < t_2 < \dots < t_n$ odległości między punktami spełniają addytywność: $|t_n - t_0| = \sum_{i=1}^n |t_i - t_{i-1}|$. Z aksjomatu 1 zastosowanego do prostej (jako przestrzeni L^1 -zanurzalnej) wynika, że przyrosty $g(t_1) - g(t_0), g(t_2) - g(t_1), \dots, g(t_n) - g(t_{n-1})$ są niezależne. Z aksjomatu 3 wiemy, że rozkład przyrostu $g(t+s) - g(t)$ zależy wyłącznie od s , co oznacza stacjonarność przyrostów. Ciągłość stochastyczna wynika wprost z aksjomatu 2 (zbieżność prawie na pewno implikuje zbieżność według prawdopodobieństwa). Zatem g na prostej spełnia wszystkie cztery warunki definicji procesu Lévy'ego.

Aksjomat 2 mówi, że proces ma wersję o ciągłych trajektoriach, więc proces Lévy'ego o tej własności musi mieć zerową miarę skoków: $\nu \equiv 0$.

Dla procesu Lévy'ego z $\nu \equiv 0$ reprezentacja Lévy'ego–Chinczyna redukuje się do postaci czysto gaussowskiej. Logarytm funkcji charakterystycznej przyrostu $g(d) - g(0)$ wynosi zatem:

$$\ln \mathbb{E}[e^{it(g(d)-g(0))}] = i\gamma d t - \frac{1}{2}\sigma^2 d^2 t^2,$$

co jest funkcją charakterystyczną rozkładu normalnego $\mathcal{N}(\gamma d, \sigma^2 d)$. Z równości (33) wynika, że dokładnie ten sam rozkład normalny ma przyrost $g(x) - g(y)$ w S dla dowolnych x, y takich, że $\mu(x, y) = d$.

Z symetrii metryki ($d(x, y) = d(y, x)$) i aksjomatu 3 wynika, że rozkład przyrostu jest symetryczny względem 0:

$$g(x) - g(y) \stackrel{d}{=} g(y) - g(x) = -(g(x) - g(y)).$$


Dla rozkładu normalnego $\mathcal{N}(\gamma d, \sigma^2 d)$ symetria względem zera jest równoważna warunkowi $\gamma = 0$. Otrzymujemy zatem $g(x) - g(y) \sim \mathcal{N}(0, \sigma^2 d)$. Oznaczając $c = \sigma^2 \in \mathbb{R}_+$, dostajemy tezę lematu:

$$g(x) - g(y) \sim \mathcal{N}(0, c \cdot d(x, y)).$$

□

4.2 Izometryczne zanurzanie w prostopadłościach w L^1

Z faktu, że dla każdej pary punktów rozkład brzegowy $g(x) - g(y)$ jest normalny dla dowolnego x, y , pojawia się hipoteza, iż proces $g(x)$ jest gaussowski. W celu jej udowodnienia chcemy przedstawić rozkład łączny jako kombinację liniową niezależnych, jednowymiarowych rozkładów normalnych. Uwzględniając aksjomat 1, naturalnym środowiskiem staje



Rysunek 1: Rysunek hiper-równoległoscianu w L^1 .

się przestrzeń L^1 , a konkretnie zawarte w niej hiper-równoległosciany, ponieważ na niej każde ortogonalne przyrosty spełniają warunek addytywności.

Definicja 4.4 (Hiper-równoległoscian w L^1). Hiper-równoległoscianem o wymiarze d nazywamy zbiór wierzchołków $V \subset L^1(\mathbb{R}^d)$, których współrzędne przyjmują wartości ze zbiorów $\{0, a_k\}$ dla $k = 1, \dots, d$.

Definicja 4.5 (Izometryczne zanurzenie). Odwzorowanie $\Phi : (S, d_S) \rightarrow (V, d_V)$ nazywamy izometrycznym zanurzeniem, jeżeli dla każdego $x, y \in S$ zachodzi $d_S(x, y) = d_V(\Phi(x), \Phi(y))$.

Lemat 4.2 (o izometrycznym zanurzeniu w hiper-równoległoscian w L^1). Niech $X = \{x_1, \dots, x_n\} \subset (S, d)$, gdzie d jest L^1 -zanurzalna. Wówczas istnieje izometryczne odwzorowanie $\Phi : X \rightarrow \mathbb{R}^{2^n - 1}$ w przestrzeń L^1 , takie że obraz $\Phi(X)$ stanowi podzbiór wierzchołków $(2^n - 1)$ -wymiarowego hiper-równoległoscianu.

Dowód. Ponieważ cała przestrzeń S jest L^1 -zanurzalna, to z definicji 2.10 dla naszego wybranego podzbioru X istnieją nieujemne wagi $a_J \geq 0$ (dla wszystkich niepustych $J \subset X$) takie, że dla dowolnych $x_i, x_k \in X$ zachodzi równość (21). Zatem niech $\mathcal{J} = \mathcal{P}(\{1, \dots, n\}) \setminus \emptyset$ będzie rodziną wszystkich niepustych podzbiorów indeksów punktów w X . Definiujemy odwzorowanie $\Phi : X \rightarrow \mathbb{R}^{|\mathcal{J}|}$ następująco. Dla każdego punktu $x_i \in X$, wektor $\Phi(x_i) = \mathbf{v}_i$ ma współrzędne indeksowane podzbiarami $J \in \mathcal{J}$:

$$(\Phi(x_i))_J = \begin{cases} a_J & \text{jeśli } i \in J, \\ 0 & \text{jeśli } i \notin J. \end{cases}$$

Ponieważ każda współrzędna przyjmuje wartości z dyskretnego zbioru $\{0, a_J\}$, obraz $\Phi(X)$ jest zbiorem wierzchołków hiper-równoległościanu o bokach $a_J \geq 0$. Zauważmy, że odległość w normie L^1 między obrazami punktów x_i oraz x_k wynosi:

$$\|\Phi(x_i) - \Phi(x_k)\|_1 = \sum_{J \in \mathcal{J}} |(\Phi(x_i))_J - (\Phi(x_k))_J|.$$

$|(\Phi(x_i))_J - (\Phi(x_k))_J|$ jest równy a_J , gdy dokładnie jeden z indeksów $\{i, k\}$ należy do J , a w przeciwnym razie wynosi 0. Jest to tożsame z warunkiem $\delta_J(x_i, x_k) = 1$. Zatem:

$$\|\Phi(x_i) - \Phi(x_k)\|_1 = \sum_{J \in \mathcal{J}} a_J \cdot \delta_J(x_i, x_k) = d(x_i, x_k).$$

□

4.3 Niezależność lub identyczność przyrostów na bokach hiper-równoległościanu w L^1

Wiedząc już, że dowolne punkty x_n z rozpatrywanego procesu g można izometrycznie zanurzyć w hiper-równoległościan w L^1 , zbadamy w jaki sposób muszą zachowywać się przyrosty na jego bokach.

Definicja 4.6 (Identyczność zmiennych losowych). Dwie zmienne losowe X i Y określone na tej samej przestrzeni probabilistycznej $(\Omega, \mathcal{A}, \mathbb{P})$ o wartościach w tej samej przestrzeni mierzalnej nazywamy identycznymi (równymi prawie wszędzie / z prawdopodobieństwem 1), co zapisujemy jako $X = Y$ p.w., jeżeli zdarzenie, na którym się różnią, ma miarę zero:

$$\mathbb{P}(X \neq Y) = \mathbb{P}(\{\omega \in \Omega : X(\omega) \neq Y(\omega)\}) = 0. \quad (34)$$

Sformułujemy teraz następujący lemat:

Lemat 4.3 (o niezależności lub identyczności przyrostów na bokach hiper-równoległościanu w L^1). *Niech proces g opisany na przestrzeni L^1 spełnia zadane aksjomaty, w szczególności aksjomat 1 o niezależności przyrostów na kierunkach ortogonalnych. Dla dowolnych dwóch krawędzi hiper-równoległościanu w przestrzeni L^1 odpowiadających parom punktów (x_1, y_1) oraz (x_2, y_2) , przyrosty procesu na tych krawędziach są albo identyczne, albo wzajemnie niezależne. Identyczność zachodzi wtedy i tylko wtedy, gdy krawędzie te są równoległe.*

Dowód. Dowód dzielimy na dwie części: wykazanie identyczności dla krawędzi równoległych oraz niezależności dla krawędzi nierównoległych.

1. Identyczność przyrostów na krawędziach równoległych. Rozważmy dwie równoległe krawędzie hiper-równoległościanu. Możemy je zapisać jako pary punktów $(x, x + a_j)$ oraz $(y, y + a_j)$, gdzie a_j jest wektorem bazowym odpowiadającym j -temu wymiarowi prostopadłościanu. Punkt y jest przesunięty względem x wyłącznie w kierunkach ortogonalnych do a_j . Zdefiniujmy cztery zmienne losowe przyrostów:

- $X_1 = g(x + a_j) - g(x)$ (pierwsza krawędź równoległa),
- $X_3 = g(y + a_j) - g(y)$ (druga krawędź równoległa),
- $X_2 = g(y) - g(x)$ (krawędź łącząca punkty początkowe),
- $X_4 = g(y + a_j) - g(x + a_j)$ (krawędź łącząca punkty końcowe).

Z definicji tych zmiennych losowych w prostopadłościu wynika tożsamość:

$$X_1 + X_4 = g(y + a_j) - g(x) = X_2 + X_3. \quad (35)$$

Co prowadzi do równania:

$$X_1 - X_3 = X_2 - X_4. \quad (36)$$

Oznaczmy $A = X_1 - X_3$ oraz $B = X_2 - X_4$. Z powyższego mamy $A = B$ prawie na pewno. Zgodnie z aksjomatem 1, przyrosty na kierunkach ortogonalnych są niezależne. Ponieważ X_1 i X_3 reprezentują przyrosty wzdłuż wymiaru a_j , natomiast X_2 i X_4 wynikają z przemieszczenia w wymiarach ortogonalnych do a_j , otrzymujemy następujące zależności:

- X_1 jest parami niezależne od X_2 oraz od X_4 ,
- X_3 jest parami niezależne od X_2 oraz od X_4 .

Z niezależności wynika zerowa kowariancja:

$$\text{Cov}(X_1, X_2) = \text{Cov}(X_1, X_4) = \text{Cov}(X_3, X_2) = \text{Cov}(X_3, X_4) = 0.$$

Obliczmy kowariancję A i B :

$$\begin{aligned} \text{Cov}(A, B) &= \text{Cov}(X_1 - X_3, X_2 - X_4) \\ &= \text{Cov}(X_1, X_2) - \text{Cov}(X_1, X_4) - \text{Cov}(X_3, X_2) + \text{Cov}(X_3, X_4) \\ &= 0. \end{aligned}$$

Skoro jednak $A = B$ p.n., to $\text{Cov}(A, B) = \text{Cov}(A, A) = \text{Var}(A)$. Zatem $\text{Var}(A) = 0$, co oznacza, że A jest stała prawie na pewno.

Z aksjomatu 3 (rozkład przyrostu zależy wyłącznie od odległości) wynika, że X_1 i X_3 mają ten sam rozkład (odpowiadają krawędziom o identycznej długości $|a_j|$), więc $\mathbb{E}[X_1] = \mathbb{E}[X_3]$ i w konsekwencji $\mathbb{E}[A] = 0$. Stała o zerowej wartości oczekiwanej i zerowej wariancji musi być zerem:

$$A = 0 \quad \text{p.n.}, \quad (37)$$

co implikuje:

$$X_1 = X_3 \quad \text{p.n.} \quad (38)$$

2. Niezależność przyrostów na krawędziach nierównoległych. Rozważmy dowolny skończony układ krawędzi odpowiadających kierunkom $a_{i_1}, a_{i_2}, \dots, a_{i_m}$, gdzie $i_1, i_2, \dots, i_m$ są różne. Na mocy udowodnionej powyżej własności identyczności, przyrost na dowolnej krawędzi $(y, y + a_k)$ jest identyczny z przyrostem na krawędzi bazowej startującej z zera układu $(0, a_k)$. Wystarczy zatem wykazać, że przyrosty $g(a_{i_1}) - g(0), g(a_{i_2}) - g(0), \dots, g(a_{i_m}) - g(0)$ są wzajemnie niezależne.

W przestrzeni L^1 punkty $0, a_{i_1}, a_{i_2}, \dots, a_{i_m}$ oraz ich suma $a_{i_1} + a_{i_2} + \dots + a_{i_m}$ tworzą wierzchołki hiper-równoległościanu. Kluczową własnością normy L^1 jest addytywność odległości na kierunkach ortogonalnych:

$$d(a_{i_1} + a_{i_2} + \dots + a_{i_m}, 0) = d(a_{i_1}, 0) + d(a_{i_2}, 0) + \dots + d(a_{i_m}, 0).$$

Zatem ścieżka $0 \rightarrow a_{i_1} \rightarrow a_{i_1} + a_{i_2} \rightarrow \dots \rightarrow a_{i_1} + a_{i_2} + \dots + a_{i_m}$ spełnia warunek addytywności dystansu.

Stosując aksjomat 1 do tej ścieżki, otrzymujemy, że przyrosty $g(a_{i_1}) - g(0), g(a_{i_1} + a_{i_2}) - g(a_{i_1}), \dots, g(a_{i_1} + \dots + a_{i_m}) - g(a_{i_1} + \dots + a_{i_{m-1}})$ są wzajemnie niezależne. Z udowodnionej wcześniej identyczności przyrostów na krawędziach równoległych wynika jednak, że każdy z tych przyrostów jest równy odpowiedniemu przyrostowi na krawędzi bazowej, np. $g(a_{i_1} + a_{i_2}) - g(a_{i_1}) = g(a_{i_2}) - g(0)$ prawie na pewno.

W konsekwencji cały układ przyrostów bazowych $\{g(a_{i_k}) - g(0)\}_{k=1}^m$ jest wzajemnie niezależny. Ponieważ wybór kierunków $i_1, \dots, i_m$ był dowolny, oznacza to, że wszystkie przyrosty na wzajemnie ortogonalnych krawędziach hiper-równoległościanu są wzajemnie niezależne. $\square$

4.4 Twierdzenie (o gaussowskości procesu)

Powyższe lematy dostarczają wszystkich narzędzi niezbędnych do udowodnienia głównego twierdzenia. Korzystając z faktu, że dla każdego x, y rozkład brzegowy $g(x) - g(y)$ jest normalny (lemat 4.1) oraz opierając się na lemacie 4.2 i lemacie 4.3, można sformułować i udowodnić następujące twierdzenie:

Twierdzenie 4.3 (o gaussowskości procesu). *Niech (S, d) będzie L^1 -zanurzalną przestrzenią metryczną o skończonym wymiarze metrycznym $D < \infty$. Jeżeli proces $g(x)$ spełnia aksjomaty 1, 2, 3 na tej przestrzeni, to jest on procesem gaussowskim o wartości oczekiwanej 0 i kowariancji:*

$$\text{Cov}(g(x), g(y)) = \frac{c}{2} (d(x, x_0) + d(y, x_0) - d(x, y)), \quad (39)$$

gdzie x_0 jest punktem zerowym procesu.

Dowód. Rozważmy dowolny skończony zbiór punktów $\{x_0, x_1, \dots, x_n\} \subset S$. Zgodnie z lematem 4.2, punkty te możemy izometrycznie rzutować na wierzchołki $v_0, v_1, \dots, v_n$ hiper-równoległościanu w przestrzeni L^1 . Niech $\mathcal{J}$ będzie zbiorem wymiarów tego hiper-równoległościanu, a $a_J \geq 0$ długością krawędzi w wymiarach $J \in \mathcal{J}$.

Dla każdego J niech Z_J będzie przyrostem na jego krawędzi. Zgodnie z lematem 4.3, przyrosty $\{Z_J\}_{J \in \mathcal{J}}$ są wzajemnie niezależne (jako przyrosty na kierunkach ortogonalnych w L^1) oraz każdy przyrost $g(x_i) - g(x_0)$ można zapisać jako sumę przyrostów po krawędziach prostopadłościanu łączących odpowiednie wierzchołki. Ponieważ krawędzie równoległe dają identyczne przyrosty (lemat 3), mamy:

$$g(v_i) - g(v_0) = \sum_{J \in \mathcal{J}_i} Z_J, \quad (40)$$

gdzie $\mathcal{J}_i$ jest zbiorem wymiarów k takich, że $(v_i)_k \neq (v_0)_k$.

Z lematu 4.2 wiemy, że każdy przyrost brzegowy Z_J ma rozkład normalny $N(0, c \cdot a_J)$. Ponieważ wektor $(g(v_1) - g(v_0), \dots, g(v_n) - g(v_0))^T$ jest liniową kombinacją niezależnych zmiennych o rozkładach normalnych, posiada on z definicji rozkład gaussowski. Z kolei z aksjomatu 3 $(g(x_1) - g(x_0), \dots, g(x_n) - g(x_0))^T \stackrel{d}{=} (g(v_1) - g(v_0), \dots, g(v_n) - g(v_0))^T$, zatem g na dowolnym S jest gaussowski.

Przejdźmy zatem do wyznaczenia funkcji średniej i kowariancji. Wartość oczekiwana procesu wynosi $\mathbb{E}[g(x) - g(x_0)] = 0$ (lemat 4.1). Aby wyznaczyć kowariancję, skorzystamy z tożsamości polaryzacyjnej dla wariancji:

$$2 \operatorname{Cov}(A, B) = \operatorname{Var}(A) + \operatorname{Var}(B) - \operatorname{Var}(A - B). \quad (41)$$

Podstawiając $A = g(x) - g(x_0)$ oraz $B = g(y) - g(x_0)$, zauważamy, że $A - B = g(x) - g(y)$. Korzystając z lematu 4.1 ($\operatorname{Var}(g(u) - g(v)) = c \cdot d(u, v)$), otrzymujemy:

$$\operatorname{Cov}(g(x) - g(x_0), g(y) - g(x_0)) = \frac{1}{2} [cd(x, x_0) + cd(y, x_0) - cd(x, y)]. \quad (42)$$

Wyłączając stałą c przed nawias oraz korzystając z faktu, że $g(x_0) = 0$ otrzymujemy tezę twierdzenia:

$$\operatorname{Cov}(g(x), g(y)) = \operatorname{Cov}(g(x) - g(x_0), g(y) - g(x_0)) = \frac{c}{2} (d(x, x_0) + d(y, x_0) - d(x, y)). \quad (43)$$

□

4.5 Istnienie i własności procesu gaussowskiego

Wyprowadzona wcześniej funkcja

$$K(x, y) = \frac{c}{2} (d(x, x_0) + d(y, x_0) - d(x, y)), \quad c > 0, \quad (44)$$

jest (jak udowodniliśmy wcześniej) jedynym kandydatem na funkcję kowariancji procesu logarytmicznych przyrostów g (względem ustalonego punktu referencyjnego x_0 , przy czym $g(x_0) = 0$ prawie na pewno). W tej sekcji udowodnimy, że K jest poprawnie określonym jądrem kowariancji (jest symetryczne i nieujemnie określone), zatem istnieje scentrowany proces gaussowski $\{g(x)\}_{x \in S}$ o kowariancji K , oraz że otrzymany w ten sposób proces gaussowski spełnia wszystkie trzy przyjęte wcześniej aksjomaty: lokalności, addytywności i niezależności oraz ciągłości.

Twierdzenie 4.4. Niech (S, d) będzie L^1 -zanurzalną przestrzenią metryczną o skończonym wymiarze metrycznym $D < \infty$ i niech $c > 0$. Funkcja K dana wzorem (44) jest symetryczna i nieujemnie określona. Odpowiadający jej scentrowany proces gaussowski $\{g(x)\}_{x \in S}$ istnieje i spełnia aksjomaty 1, 2 oraz 3.

Dowód. Zauważmy, że symetria $K(x, y) = K(y, x)$ wynika wprost z symetrii metryki d . Aby wykazać nieujemną określoność, weźmy dowolny skończony zbiór punktów $\{x_0, x_1, \dots, x_n\} \subset S$ oraz dowolne stałe $a_1, \dots, a_n \in \mathbb{R}$. Wprowadźmy dodatkową stałą a_0 taką, że:

$$\sum_{i=0}^n a_i = 0. \quad (45)$$

Ponieważ (jak już podkreśliliśmy w rozdziale 2.3) każda przestrzeń L^1 -zanurzalna jest przestrzenią typu ujemnego Schoenberga, spełniony jest warunek:

$$\sum_{i=0}^n \sum_{j=0}^n a_i a_j d(x_i, x_j) \leq 0. \quad (46)$$

Rozpiszmy podwójną sumę, wyodrębniając składniki zawierające punkt referencyjny x_0 :

$$\sum_{i,j=0}^n a_i a_j d(x_i, x_j) = \underbrace{\sum_{i,j=1}^n a_i a_j d(x_i, x_j)}_{S_1} + 2 \underbrace{\sum_{i=1}^n a_i a_0 d(x_i, x_0)}_{S_2} + a_0^2 d(x_0, x_0).$$

Ponieważ $d(x_0, x_0) = 0$, ostatni składnik znika. Zauważmy, że $a_0 = -\sum_{k=1}^n a_k$, zatem składnik S_2 możemy wyrazić jako

$$S_2 = \sum_{i=1}^n a_i \left(-\sum_{k=1}^n a_k \right) d(x_i, x_0) = -\sum_{i=1}^n \sum_{k=1}^n a_i a_k d(x_i, x_0).$$

Korzystając z symetrii metryki, równoważnie zapisujemy

$$S_2 = -\frac{1}{2} \sum_{i=1}^n \sum_{k=1}^n a_i a_k (d(x_i, x_0) + d(x_k, x_0)),$$

skąd $2S_2 = -\sum_{i=1}^n \sum_{k=1}^n a_i a_k (d(x_i, x_0) + d(x_k, x_0))$. Wstawiamy to do nierówności (46):

$$\sum_{i,j=1}^n a_i a_j d(x_i, x_j) - \sum_{i=1}^n \sum_{k=1}^n a_i a_k (d(x_i, x_0) + d(x_k, x_0)) \leq 0.$$

$$\sum_{i=1}^n \sum_{k=1}^n a_i a_k (d(x_i, x_0) + d(x_k, x_0)) - \sum_{i,j=1}^n a_i a_j d(x_i, x_j) \geq 0.$$

Dzieląc obie strony przez $2/c > 0$, dostajemy:

$$\sum_{i=1}^n \sum_{k=1}^n a_i a_k \frac{c}{2} (d(x_i, x_0) + d(x_k, x_0) - d(x_i, x_k)) \geq 0,$$

czyli

$$\sum_{i,j=1}^n a_i a_j K(x_i, x_j) \geq 0.$$

Dowodzi to, że K jest nieujemnie określona na dowolnych przestrzeniach L^1 -zanurzanych (a nawet na dowolnej metryce Schoenberga). Na mocy twierdzenia o istnieniu procesu gaussowskiego 2.5, istnieje scentrowany proces $\{g(x)\}_{x \in S}$ o kowariancji danej przez K . Teraz sprawdzimy, czy proces g spełnia założone aksjomaty.

Aksjomat 3 (lokalność i spójność). Wyprowadzimy najpierw ogólny wzór na kowariancję między dwoma przyrostami. Dla dowolnych czterech punktów $x, y, z, w \in S$:

$$\begin{aligned} \text{Cov}(g(x) - g(y), g(z) - g(w)) &= \text{Cov}(g(x), g(z)) - \text{Cov}(g(x), g(w)) \\ &\quad - \text{Cov}(g(y), g(z)) + \text{Cov}(g(y), g(w)) \\ &= \frac{c}{2} \left[(d(x, x_0) + d(z, x_0) - d(x, z)) \right. \\ &\quad \left. - (d(x, x_0) + d(w, x_0) - d(x, w)) \right. \\ &\quad \left. - (d(y, x_0) + d(z, x_0) - d(y, z)) \right. \\ &\quad \left. + (d(y, x_0) + d(w, x_0) - d(y, w)) \right] \\ &= \frac{c}{2} (-d(x, z) - d(y, w) + d(x, w) + d(y, z)). \end{aligned} \quad (47)$$

Zauważmy, że wszystkie wyrażenia zawierające punkt odniesienia x_0 uległy skróceniu. Oznacza to, że kowariancja między dowolnymi przyrostami zależy wyłącznie od odległości między punktami tworzącymi te przyrosty, a nie od x_0 .

Zatem jeżeli weźmiemy skończony układ par punktów $(x_1, x_2), (x_3, x_4), \dots, (x_{2n-1}, x_{2n})$ należących do S oraz odpowiadający im wektor przyrostów

$$\Delta = [g(x_1) - g(x_2), g(x_3) - g(x_4), \dots, g(x_{2n-1}) - g(x_{2n})]^T.$$

to, ponieważ g jest procesem gaussowskim, wektor Δ z definicji ma łączny rozkład gaussowski. Jego wartość oczekiwana wynosi zero, a elementy macierzy kowariancji dane są bezpośrednio przez wzór (47). Prawa strona zależy wyłącznie od wartości metryki d na zbiorze $\{x_1, x_2, \dots, x_{2n}\}$. Zatem łączny rozkład wektora Δ jest w pełni zdeterminowany przez wzajemne odległości między wszystkimi punktami tworzącymi pary.

Aksjomat 1 (addytywność i niezależność). Załóżmy, że punkty $x_0, x_1, \dots, x_n \in S$ tworzą ścieżkę addytywną, tzn. spełniają

$$\sum_{i=1}^n d(x_{i-1}, x_i) = d(x_0, x_n). \quad (48)$$

Niech $X_i = g(x_i) - g(x_{i-1})$ dla $i = 1, \dots, n$. Pokażemy, że zmienne te są wzajemnie niezależne.

Ponieważ g jest procesem gaussowskim, wektor $(X_1, \dots, X_n)$ ma łączny rozkład gaussowski. Wystarczy zatem wykazać, że są one parami nieskorelowane. Dla dowolnych $1 \leq i < j \leq n$ stosujemy ogólny wzór (47) z podstawieniem $x = x_i$, $y = x_{i-1}$, $z = x_j$, $w = x_{j-1}$:

$$\text{Cov}(X_i, X_j) = \frac{c}{2}(-d(x_i, x_j) - d(x_{i-1}, x_{j-1}) + d(x_i, x_{j-1}) + d(x_{i-1}, x_j)).$$

Z założenia wynika, że punkty $x_{i-1}, x_i, x_{j-1}, x_j$ leżą na jednej ścieżce addytywnej, a więc

$$d(x_i, x_j) + d(x_{i-1}, x_{j-1}) = d(x_{i-1}, x_i) + 2d(x_i, x_{j-1}) + d(x_{j-1}, x_j) = d(x_i, x_{j-1}) + d(x_{i-1}, x_j).$$

Zatem $\text{Cov}(X_i, X_j) = 0$, co jest równoważne niezależności (gdyż proces g jest gaussowski), zatem przyrosty $X_1, \dots, X_n$ są niezależne, czego wymaga aksjomat 1.

Aksjomat 2 (ciągłość). Zakładamy, że przestrzeń L^1 -zanurzalna (S, d) posiada skończony wymiar metryczny $D < \infty$. Wprowadźmy więc twierdzenie, które pomoże nam w dowodzie ciągłości.

Twierdzenie 4.5 (Twierdzenie Kołmogorowa-Chentsova o ciągłości). *Niech $\{X_t\}_{t \in T}$ będzie procesem stochastycznym indeksowanym przestrzenią metryczną o skończonym wymiarze D . Jeżeli istnieją stałe $\alpha, \beta, C_{KC} > 0$ takie, że dla wszystkich $s, t \in T$ spełnione jest oszacowanie:*

$$\mathbb{E}[|X_t - X_s|^\alpha] \leq C_{KC} \cdot d(t, s)^{D+\beta},$$

to proces X posiada modyfikację o ciągłych trajektoriach.

Dowód twierdzenia można znaleźć w artykule [18].

Z lematu 1 wiemy, że dla dowolnych $x, y \in S$ przyrost $g(x) - g(y)$ ma rozkład $\mathcal{N}(0, c \cdot d(x, y))$. Z własności rozkładu normalnego, centralny moment parzysty rzędu $2m$ (gdzie $m \in \mathbb{N}$) wynosi:

$$\mathbb{E}[(g(x) - g(y))^{2m}] = (2m - 1)!! \cdot c^m \cdot d(x, y)^m.$$

Aby spełnić założenia twierdzenia Kołmogorowa-Chentsova, dobieramy wystarczająco duży moment rozkładu, kładąc $m > D$. Przyjmując $\beta = m - D > 0$ oraz stałą $C_{KC} = (2m - 1)!! \cdot c^m$, otrzymujemy oszacowanie:

$$\mathbb{E}[(g(x) - g(y))^{2m}] = C_{KC} \cdot d(x, y)^{D+\beta}.$$

Powyższa relacja spełnia wprost warunki twierdzenia dla przestrzeni o wymiarze D . Gwarantuje to istnienie modyfikacji procesu g o ciągłych trajektoriach na całej przestrzeni S . □

Podsumowując, otrzymujemy więc również implikację w drugą stronę. To oznacza, że proces g spełnia aksjomaty wtedy i tylko wtedy, gdy jest procesem gaussowskim wyznaczonym wcześniej.

4.6 Parowa estymacja parametru skali oraz algorytmiczny potok obliczeniowy

Wyprowadzona w poprzednich rozdziałach struktura teoretyczna procesu gaussowskiego nakłada na wariancję przyrostów logarytmu funkcji gęstości liniową zależność od dystansu metrycznego: $\text{Var}(g(x) - g(y)) = c \cdot d(x, y)$. Parametr $c \in \mathbb{R}_+$ (oraz odpowiadający mu hiperparametr $\ell = 1/c$) pełni kluczową rolę regularyzatora geometrycznego - definiuje on spodziewaną intensywność fluktuacji pola losowego na jednostkę odległości w dowolnej przestrzeni L^1 -zanurzalnej.

4.6.1 Ogólna procedura parowej estymacji parametru skali c

Proces wyznaczania hiperparametru przebiega według następującego ogólnego schematu algorytmicznego:

1. **Log-transformacja i regularyzacja danych:** Dla dowolnego zbioru komórek siatki lub punktów pomiarowych, w których odnotowano niezerową liczbę zliczeń obserwacji (n_{obs}), wyznaczany jest wektor logarytmu zliczeń w poszczególnych punktach Z . W celu uniknięcia osobliwości w zerze stosuje się ogólne wygładzanie Laplace'a z parametrem $\delta = 1.0$:

$$Z_i = \ln(n_i + 1.0), \quad i \in \{1, \dots, n_{\text{obs}}\}. \quad (49)$$

2. **Konstrukcja parowych macierzy geometrycznych i stochastycznych:** Dla wszystkich unikalnych par punktów (x_i, x_j) w przestrzeni wyznaczana jest odległość metryczna $d(x_i, x_j)$. Jednocześnie budowana jest macierz kwadratów różnic wartości empirycznych:

$$\Delta_{ij} = (Z_i - Z_j)^2. \quad (50)$$

3. **Odporna estymacja za pomocą mediany ilorazów:** Zakładamy, że $\mathbb{E}[(Z_i - Z_j)^2] \approx \sigma^2 \cdot d(x_i, x_j)$. Przekształcając tę relację, dla każdej pary punktów oddalonych o dystans $d(x_i, x_j) > 10^{-8}$ oblicza się cząstkowy iloraz skali:

$$R_{ij} = \frac{d(x_i, x_j)}{\Delta_{ij} + 10^{-12}}. \quad (51)$$

Ze względu na fakt, że rzadkie dane wejściowe bywają obarczone silnym szumem losowym, klasyczne podejście oparte na średniej arytmetycznej zastąpiono estymatorem centralnym opartym na medianie rozkładu parowych ilorazów R_{ij} :

$$\ell = (\text{med}(\{R_{ij} : i < j\})). \quad (52)$$

4. **Stabilizacja numeryczna i mapowanie hiperparametru:** Uzyskany numerycznie parametr ℓ poddawany jest procedurze przycinania (*clipping*) do fizycznie uzasadnionego zakresu dziedziny $\ell \in [\ell_{\min}, \ell_{\max}]$. Ostatecznie poszukiwany parametr zmienności geometrycznej c wyznaczany jest jako odwrotność długości skali:

$$c = \frac{1}{\ell}. \quad (53)$$

4.6.2 Ogólny algorytm

- **Krok 1 (Estymacja skali geometrycznej):** Automatyczne wyznaczenie optymalnego hiperparametru c za pomocą zaprezentowanej wyżej ogólnej procedury parowej opartej na medianie.
- **Krok 2 (Macierz kowariancji i rozkład a priori):** Skonstruowanie macierzy kowariancji $\Sigma(c)$ procesu gaussowskiego g przy użyciu aksjomatycznego jądra odległościowego wyprowadzonego dla przestrzeni L^1 -zanurzalnych:

$$\Sigma_{ij}(c) = \text{Cov}(g(x_i), g(x_j)) = \frac{c}{2} (d(x_i, x_0) + d(x_j, x_0) - d(x_i, x_j)). \quad (54)$$

- **Krok 3 (Mapowanie nieliniowe i wnioskowanie MCMC):** Przetransformowanie procesu g w rozkład prawdopodobieństwa f za pomocą wielomianowej transformacji logistycznej (*Softmax*).

$$f(x) = \frac{\exp(g_{x_0}(x))}{\int_S \exp(g_{x_0}(u)) d\mu(u)}. \quad (55)$$

Następnie próbkowanie z gęstości *a posteriori* realizowane jest numerycznie przy użyciu algorytmu Metropolis-Hastings (MCMC) z uwzględnieniem wielomianowej funkcji wiarygodności wyprowadzonej w Sekcji 2.1.2

5 Teoretyczne przygotowanie eksperymentu

W niniejszym rozdziale przygotowujemy podstawy teoretyczne i metodyczne eksperymentu. Zaczniemy od sformułowania wymagań, jakie musi spełniać zbiór danych, aby był zgodny z założeniami modelu. Następnie zaprezentujemy konkretny zbiór danych oraz przeanalizujemy, w jakim stopniu spełnia on te wymagania. W dalszej kolejności omówimy konieczność wstępnego przetwarzania danych, a w rozdziale 5.4 przeprowadzimy dowód L^1 -zanurzalności metryki geodezyjnej na kuli S^2 .

5.1 Założenia dotyczące danych testowych

Zgodnie z założeniami pracy przestrzeń metryczna (S, d) jest L^1 -zanurzalna i o skończonym wymiarze metrycznym. Ponadto poszukiwana funkcja gęstości prawdopodobieństwa f (wyznaczana względem miary μ) jest ciągła względem d . Testowy zbiór danych musi zatem spełniać kilka naturalnych warunków. Przestrzeń, na której definiujemy dane, musi być wyposażona w metrykę, być L^1 -zanurzalna i mieć skończony wymiar metryczny. Tylko wtedy można bezpośrednio zastosować wyprowadzone jądro kowariancji i zagwarantować ciągłość trajektorii procesu. Drugim wymaganiem jest, aby rzeczywista estymowana gęstość była ciągła, tzn. nie zawierała gwałtownych skoków ani osobliwości, które odpowiadałyby niezerowej mierze Lévy’ego, a tym samym naruszały Aksjomat 2. Kolejnym ważnym założeniem jest, by dane nie pochodziły z prostej rodziny parametrycznej: model nieparametryczny wypadalby dużo gorzej niż modele parametryczne konkretnych rozkładów analitycznych, gdyż informacja o konkretnym wyglądzie analitycznym jest pewną informacją wychodzącą poza ciągłość na metryce, podczas gdy idealny zbiór danych powinien być surowy i złożony, o nieregularnych kształtach i lokalnych fluktuacjach.

5.2 Dane AquaMaps i ich zgodność z założeniami

Mając zdefiniowane te założenia, możemy przejść do wybrania źródła danych. Jako źródło danych eksperymentalnych wybraliśmy zbiór opisujący bogactwo gatunkowe (*marine species richness*) pochodzące z projektu AquaMaps [19]. W przeciwieństwie do surowych danych obserwacyjnych, które często są niekompletne lub obarczone błędem selekcji, system ten dostarcza zagregowanych prognoz na globalnej siatce o rozdzielczości $0,5^\circ \times 0,5^\circ$ (ok. 50 km na równiku). Dane te powstają poprzez nałożenie na siebie tysięcy map występowania różnych gatunków. Jej wartość w danej komórce informuje nas, dla ilu gatunków obszar ten stanowi odpowiednie siedlisko. Choć dane te nie mają w ścisłym sensie natury ciągłej, gdyż są zdefiniowane na dyskretnej siatce, ich wysoka rozdzielczość sprawia, że dobrze aproksymują ciągłe pole.

Będziemy więc estymować tło oceaniczne pod względem bogactwa gatunkowego. Z perspektywy teoretycznej zbiór ten stanowi właściwy zbiór danych eksperymentalnych dla modelu aksjomatycznego. Przestrzeń geograficzna na sferze z odległością wielkiego koła

(metryką Harvesine'a) jest - co zostanie formalnie wykazane w Sekcji 5.4 - L^1 -zanurzalna w sensie definicji 2.10 oraz ma skończony wymiar metryczny. Ponadto rozkład tła oceanicznego ten nie jest żadnym rozkładem analitycznym. Jest on trudny, nieregularny i ma złożony kształt.

Surowe dane z AquaMaps nie będą jednak dobrymi danymi testowymi. Choć bogactwo gatunkowe na tle oceanicznym zachowuje się w sposób ciągły i spełnia aksjomaty, to dane z AquaMaps zawierają również takie punkty jak rafy koralowe czy gwałtowne zjawiska przybrzeżne. Tego rodzaju punkty generują skokowe zmiany wartości, które poważnie naruszają wymóg ciągłości trajektorii i odpowiadają niezerowej mierze Lévy'ego, naruszając tym samym Aksjomat 2. Z tego powodu, aby w pełni wykorzystać potencjał tych danych, przeprowadzimy ich przetwarzanie i przekształcimy je w taki sposób, aby przedstawiały wartości tylko tła oceanicznego.

5.3 Konieczność wstępnego przetwarzania

Aby więc zrealizować przetwarzanie, które zasygnalizowaliśmy powyżej, najpierw ograniczymy obszar badań do Oceanu Spokojnego, gdyż jest on jednym spójnym akwenem. Brak barier lądowych na nim pozwala nam na zastosowanie zwykłej metryki Haversine'a. W przeciwnym razie bariery lądowe generowałyby "anomalie" i wymuszały, abyśmy użyli bardziej skomplikowanej metryki. Ograniczając się do jednego spójnego akwenu, odległość wielkiego koła między punktami odpowiada rzeczywistym drogom morskim, a macierz kowariancji zachowuje prostą postać.

Po drugie, jak podkreśliliśmy w poprzednim podrozdziale, aby zrealizować założenie ciągłości, musimy usunąć wartości odstające, które są wartościami lokalnych punktów bioróżnorodności, takich jak np. rafy koralowe, a nie tła oceanicznego. Punkty takie wprowadzają skokowe zmiany logarytmu gęstości, co narusza założenie o ciągłości trajektorii (Aksjomat 2). W następnej kolejności odrzucimy cienki pas przybrzeżny, ponieważ wartości na nim gwałtownie się zmieniają i nie należą do tła oceanicznego.

Kolejnym problemem technicznym jest złożoność obliczeniowa. Operacje na macierzach kowariancji mają złożoność $O(n^3)$ względem ilości punktów na siatce. Konieczne jest zatem przerzedzenie siatki. Dlatego stosujemy systematyczne przerzedzanie siatki (ang. *subsampling*), zachowując przy tym reprezentatywność przestrzennego rozkładu danych. Szczegółowy opis użytych procedur (progi liczbowe, szerokość bufora, stopień przerzedzenia) oraz ich implementację w języku Python zamieszczamy w rozdziale 6.

5.4 L^1 -zanurzalność metryki Haversine'a

Udowodnijmy zatem, że metryka Haversine'a na kuli S^2 spełnia warunek L^1 -zanurzalności przyjęty w definicji 2.10:

Twierdzenie 5.1 (L^1 -zanurzalność sfery z metryką geodezyjną). *Niech $x_1, \dots, x_n$ będą dowolnymi punktami na sferze S^2 , a $d(x_i, x_j)$ kątem środkowym między nimi pomnożonym*

przez promień. Istnieją nieujemne liczby a_J oraz podzbiory $J \subset \{1, \dots, n\}$ takie, że

$$d(x_i, x_j) = \frac{1}{4}r \sum_J a_J \delta_J(x_i, x_j),$$

gdzie $\delta_J(x, y) = 1$, gdy $|\{x, y\} \cap J| = 1$, a 0 w przeciwnym wypadku. Zatem każdy skończony podzbiór przestrzeni (S^2, d) jest L^1 -zanurzalny, co wobec definicji 2.10 oznacza, że (S^2, d) jest przestrzenią L^1 -zanurzalną.

Dowód. Weźmy więc punkty x_i i dla każdego z nich rozważmy otwartą półkulę $H_i = \{y \in S^2 : \langle y, x_i \rangle > 0\}$ (półkulę o "czubku" w x_i).


$\{H_i\}_{i=1}^n$ rozcina sferę S^2 na m rozłącznych pól $C_1, \dots, C_m$. Oznaczmy pola powierzchni tych pól odpowiednio $a_1, \dots, a_m$. Każde pole C_k leży wewnątrz jakiegoś zbioru półkul lub zbioru pustego. Niech $J_k = \{i \in \{1, \dots, n\} : C_k \subset H_i\}$. Weźmy więc $H_i \triangle H_j$ (suma pól minus dwa razy część wspólna). Składa się ona z tych komórek, które należą do dokładnie jednej z półkul H_i, H_j .

$$\text{Area}(H_i \triangle H_j) = \sum_{k: |J_k \cap \{i, j\}|=1} a_k.$$

Z drugiej strony, pole półkuli wynosi $2\pi r^2$, a pole części wspólnej dwóch półkul o kącie α to $2\pi(1 - \alpha/\pi)r^2$. Stąd pole różnicy symetrycznej wynosi $(4\pi - 4\pi(1 - \alpha/\pi))r^2 = 4\alpha r^2$. Dzielimy przez $4r$, otrzymujemy

$$d(x_i, x_j) = \alpha r = \frac{1}{4}r \sum_{k=1}^m a_k \delta_{J_k}(x_i, x_j),$$

gdzie $\delta_{J_k}(x_i, x_j) = 1$, gdy $|J_k \cap \{i, j\}| = 1$, a 0 w przeciwnym razie. Wagi a_k są nieujemne (jako pola powierzchni), a liczba podzbiorów J_k jest skończona – w istocie nie przekracza $n^2 - n + 2$ dla $n \geq 2$. Otrzymana reprezentacja spełnia definicję L^1 -zanurzalności, jest to bowiem kombinacja stożkowa metryk cięć. $\square$



Rysunek 2: Rysunek podziału kuli na sfery przy 3 punktach.

Twierdzenie 5.2 (Skończony wymiar metryczny sfery). *Przestrzeń (S^2, d) z metryką geodezyjną ma skończony wymiar metryczny; w szczególności $D \leq 2$.*

Pole powierzchni kuli geodezyjnej o promieniu ρ rośnie proporcjonalnie do ρ^2 . Zgodnie z Lematem 4.2.12 w pracy Vershynina [20], wynika, że liczbę kul o promieniu ϵ potrzebnych do pokrycia kuli o promieniu r można ograniczyć przez $(C \cdot r/\epsilon)^2$. Zatem $D \leq 2$.

5.5 Projekt eksperymentu i metryki oceny

Możemy przejść zatem do podsumowania całego eksperymentu. Po przetworzeniu danych zgodnie z podrozdziałem 5.3 znormalizujemy wartości bogactwa gatunkowego we wszystkich n punktach siatki. Otrzymamy wtedy dyskretny rozkład prawdopodobieństwa:

$$p_{\text{true}}(x_i) = \frac{\text{value}(x_i)}{\sum_{j=1}^n \text{value}(x_j)},$$

Ten rozkład będziemy chcieli, aby nasze modele estymowały. Nie będą one miały bezpośredniego do niego dostępu, a on posłuży nam jako obiektywny punkt odniesienia do ich oceny. Zatem będziemy losować z tego rozkładu próbkę N obserwacji (dla różnych N) i będziemy sprawdzać, jak poszczególne modele sobie na nich radzą. Modele będą miały dostęp jedynie do tej próbki i do funkcji metryki pozwalającej im liczyć odległość między wylosowanymi punktami. Ich zadaniem jest odtworzenie pełnego rozkładu p_{true} na całej siatce, mając do dyspozycji tylko tę skromną próbkę N i zadaną miarę odległości.

Błędy będziemy oceniać poniższymi metrykami: (*Mean Squared Error*, MSE):

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (p_{\text{true}}(x_i) - \hat{p}(x_i))^2,$$

(*Mean Absolute Error*, MAE):

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |p_{\text{true}}(x_i) - \hat{p}(x_i)|,$$

oraz współczynnik korelacji Pearsona (r):

$$r = \frac{\sum_{i=1}^n (p_{\text{true}}(x_i) - \bar{p}_{\text{true}})(\hat{p}(x_i) - \bar{\hat{p}})}{\sqrt{\sum_{i=1}^n (p_{\text{true}}(x_i) - \bar{p}_{\text{true}})^2} \sqrt{\sum_{i=1}^n (\hat{p}(x_i) - \bar{\hat{p}})^2}},$$

gdzie $\bar{p}_{\text{true}}$ oraz $\bar{\hat{p}}$ to średnie wartości rozkładu rzeczywistego i estymowanego. Eksperymenty między modelami będziemy powtarzać wielokrotnie i korzystając z testu Friedmana z poprawką post-hoc Nemenyiego, co dodatkowo obrazujemy na diagramie różnic krytycznych (CD), będziemy mogli oceniać istotność statystyczną różnic między modelami. Model aksjomatyczny będziemy porównywać z czterema innymi podejściami: deterministycznym wygładzaniem przestrzennym, modelem Dirichleta (który traktujemy jako bazę nieuwzględniającą przestrzeni), klasycznym modelem logistyczno-normalnym Lenka oraz rodziną przestrzennych modeli sprzężonych.

6 Przeprowadzenie eksperymentu i wyniki

W tym rozdziale opisujemy techniczną realizację eksperymentu z rozdziału 5. Rozpoczniemy od implementacji numerycznej modelu autorskiego. Następnie przedstawimy proces przygotowywania danych (preprocessingu) oraz opiszemy modele referencyjne. W końcowej fazie przedstawimy metodologię testową oraz omówimy wyniki.

6.1 Implementacja numeryczna modelu autorskiego

6.1.1 Geometria jako jedyne źródło informacji a priori

Zgodnie z przyjętymi założeniami badawczymi, jedynym parametrem wejściowym modelu określającym strukturę zależności przestrzennej jest metryka przestrzeni (S, μ) . W analizowanym przypadku przestrzenią S jest powierzchnia kuli (Ziemi) z metryką μ (odległość wielkiego koła wyznaczana wzorem Haversine’a), która - jak udowodniliśmy w rozdziale 5 - jest L^1 -zanurzalna i ma skończony wymiar metryczny $D = 2$. Dzięki temu macierz kowariancji jest dodatnio określona i ma skończony rozmiar, dzięki czemu możemy bezpiecznie stosować numeryczne procedury oparte na rozkładzie Cholesky’ego. Ponadto ciągłość trajektorii jest zagwarantowana przez twierdzenie Kołmogorowa–Chentsova. Parametr c z kolei będziemy przycinać do 40000 (długości równika).

Świadomie zrezygnowaliśmy z wprowadzania poprawek anizotropowych (np. z uwzględnieniem faktu, że parametry środowiskowe często zmieniają się wolniej wzdłuż równoleżników niż południków). Choć taka wiedza mogłaby zwiększyć skuteczność modelu, stanowiłaby użycie informacji zewnętrznej, wykraczającej poza czystą strukturę metryczną. Zgodnie z założeniami o minimalności wiedzy *a priori*, model musi być zdolny do rekonstrukcji gęstości wyłącznie na podstawie geometrii i zaobserwowanych punktów, co czyni go rozwiązaniem uniwersalnym. W rezultacie chcemy stworzyć model, który nie będzie jedynie ograniczony do procesów na kuli ziemskiej, lecz będzie działał na dowolnych przestrzeniach metrycznych spełniających założenia.

6.1.2 Numeryczna poprawność macierzy kowariancji

Aby modelować gęstość prawdopodobieństwa na siatce, przechodzimy na zmienne w_i , reprezentujące logarytmiczne przyrosty względem punktu referencyjnego x_0 . Wiemy, że $\mathbf{w} = (w_1, \dots, w_{n-1})$ pochodzi z rozkładu gaussowskiego $\mathcal{N}(\mathbf{0}, \Sigma)$, gdzie macierz Σ wyprowadziliśmy w rozdziale 4:

$$\Sigma_{ij} = \frac{c}{2} (d(x_i, x_0) + d(x_j, x_0) - d(x_i, x_j)). \quad (56)$$

W poprzednich rozdziałach udowodniliśmy, że jest ona symetryczna i nieujemnie określona. Jeśli algorytm napotka błędy numeryczne, dodajemy szum (*jitter*) na przekątnej macierzy: $\Sigma' = \Sigma + \epsilon \mathbf{I}$, co stabilizuje nam numerycznie naszą macierz.

6.1.3 Wnioskowanie a posteriori

Całka funkcji wiarygodności przy transformacji logistycznej nie ma postaci zamkniętej i niemożliwe jest wyznaczenie rozwiązania analitycznego. Dokładnie to w swojej pracy omówił P. J. Lenk [9]. Zatem wnioskujemy w następujący sposób:

1. **Algorytm MCMC:** Aby próbkować z rozkładu *a posteriori* $p(\mathbf{w} \mid \text{dane})$, wykorzystujemy algorytm *Metropolis-Hastingsa* [21, 22] w ramach łańcuchów Markowa (MCMC).
2. **Generowanie próbek:** W trakcie działania algorytmu próbnik zbiera ciąg próbek $\mathbf{w}^{(k)}$.
3. **Transformacja na przestrzeń prawdopodobieństw:** Każdą zebraną próbkę $\mathbf{w}^{(k)}$ zamieniamy z powrotem na $x^{(k)}$ według wzoru:

$$x_0^{(k)} = \frac{1}{1 + \sum_{j=1}^m \exp(w_j^{(k)})}, \quad x_i^{(k)} = \frac{\exp(w_i^{(k)})}{1 + \sum_{j=1}^m \exp(w_j^{(k)})}. \quad (57)$$

4. **Wyznaczenie ostatecznej gęstości (uśrednienie):** Ostateczny wynik modelu wyznaczamy jako wartość oczekiwaną z zebranych próbek.

6.1.4 Optymalizacje wydajnościowe procedury numerycznej

W trakcie implementacji opisanego wyżej algorytmu zastosowaliśmy dwie istotne optymalizacje czasowe. Po pierwsze, macierz kowariancji Σ , wyznaczaną na etapie konstrukcji, rozkładamy na macierz dolnotrójkątną $\mathbf{L}$ tylko raz — przed rozpoczęciem próbkowania. Operacja ta ma złożoność $O(n^3)$, jednak dzięki niej w każdej iteracji algorytmu MCMC, zamiast obliczać formę kwadratową $\mathbf{u}^T \Sigma^{-1} \mathbf{u}$ w funkcji wiarygodności, rozwiązujemy układ równań $\mathbf{L} \mathbf{y} = \mathbf{u}$. To zmniejsza złożoność obliczeniową pojedynczej iteracji do $O(n^2)$. Po drugie, funkcje odpowiadające za najbardziej kosztowne obliczeniowo etapy procedury, czyli wyznaczanie logarytmu gęstości *a posteriori* (oznaczone jako `log_posterior_fast`) w algorytmie Metropolis-Hastings oraz zdefiniowaną wcześniej transformację próbek na sympleks (funkcja `x_from_w`), kompilujemy bezpośrednio do kodu maszynowego.

6.2 Przygotowanie danych

Zgodnie z podrozdziałem 5.3 wykonamy wstępne przetwarzanie danych. W pierwszym kroku zredukowaliśmy zbiór pierwotnie liczący 174 321 rekordów do obszaru Oceanu Spokojnego. W tym celu wykorzystaliśmy maskę poligonową (czyli wielokąt przybliżający granice oceanu). Po tej operacji zbiór liczył 52 938 punktów. Kolejnym krokiem było usunięcie wartości odstających. Użyliśmy do tego metody rozstępu międzykwartylowego

(IQR) z mnożnikiem 1.5. Wyznaczone granice wyniosły $[-39.0, 785.0]$. W ten sposób usunęliśmy lokalne punkty bioróżnorodności, a zostawiliśmy tło oceaniczne, na którego estymacji nam zależało. W efekcie usunięto 2 256 rekordów (ok. 4.3% danych Pacyfiku). W celu wyeliminowania błędów brzegowych oraz uwzględnienia specyfiki ekosystemów szelfowych, wprowadzono bufor bezpieczeństwa o szerokości 100 km od linii brzegowej wszystkich lądów. Punkty znajdujące się wewnątrz niego odrzuciliśmy, co zredukowało zbiór do 38 720 punktów. Ostatnim etapem przygotowania danych jest systematyczne przerzedzenie siatki poprzez wybór co k -tego punktu. Liczba punktów końcowych n dana jest wzorem $n \approx 38\,720/k$. Podsumowanie redukcji przedstawia Tabela 1.

Tabela 1: Podsumowanie etapów przygotowania danych testowych.

Etap filtracji	Liczba rekordów	Cel operacji
Zbiór surowy (AquaMaps)	174 321	Punkt wyjścia (globalny)
Obszar Pacyfiku	52 938	Spójność akwenu i metryki
Filtr IQR (Outliers)	50 682	Zapewnienie ciągłości (brak skoków)
Filtr brzegowy	38 720	Eliminacja anomalii przybrzeżnych
Finalna siatka testowa	$38\,720/k$	Optymalizacja obliczeniowa $O(n^3)$

W eksperymencie przyjęliśmy $k = 50$.

6.3 Opis modeli referencyjnych

6.3.1 Model wygładzania przestrzennego (Bayesian Spatial Smoothing)

Pierwszym modelem, do którego porównujemy nasz model aksjomatyczny, jest model wygładzania przestrzennego (ang. *Spatial Smoothing*). Nie jest on modelem bayesowskim i nie angażuje procesów gaussowskich ani nie modeluje rozkładu *a posteriori*. Używa on deterministycznych metod podobnych do IDW (ang. *Inverse Distance Weighting*). Służy on zatem do tego, aby zweryfikować, czy warto stosować podejście bayesowskie i modelować cały rozkład na przestrzeniach funkcji. Sposób obliczenia polega na dwóch krokach. W pierwszej kolejności model konstruuje macierz wag $\mathbf{W}$, gdzie $w_{ij} = \exp(-d(x_i, x_j)/\phi)$ (parametr ϕ kontroluje zasięg wygładzania). Następnie przewiduje $\hat{\mathbf{f}}$ za pomocą znormalizowanego iloczynu $\hat{\mathbf{f}} = \text{norm}(\mathbf{W} \cdot \mathbf{p}_{\text{emp}})$. Wzór na prawdopodobieństwo empiryczne to $p_{\text{emp}}(x) = \frac{k_x}{n}$, gdzie k_x to ilość wylosowanych punktów x , a n to liczba losowań.

W implementacji (klasa `BayesianSpatialSmoothing`) model służy do wyznaczenia dolnej granicy skuteczności metod przestrzennych.

6.3.2 Model Dirichleta (Non-Spatial Baseline)

Model Dirichleta kompletnie ignoruje metrykę między punktami. Dla danych kategorycznych jest on najprostszym modelem bayesowskim, więc stanowi odniesienie, czy metryka w ogóle wnosi istotną informację na temat rozkładu.

Metoda ta wykorzystuje sprzężenie rozkładu Dirichleta z rozkładem wielomianowym.

Gęstość rozkładu *a priori* Dirichleta dla wektora $\mathbf{p} = (p_1, \dots, p_n)$ ma wzór:

$$p(\mathbf{p} \mid \boldsymbol{\alpha}) = \frac{1}{B(\boldsymbol{\alpha})} \prod_{i=1}^n p_i^{\alpha_i-1}, \quad (58)$$

gdzie $B(\boldsymbol{\alpha})$ to wielowymiarowa funkcja beta, a $\boldsymbol{\alpha} = (\alpha_1, \dots, \alpha_n)$ to wektor hiperparametrów rozkładu.

Model stosuje prior $\alpha_0 = 1$ dla każdego punktu, a następnie wyznacza parametry rozkładu *a posteriori* $\alpha'_i = y_i + 1$, gdzie y_i to liczba obserwacji. Przyjmuje on zatem następującą postać:

$$\hat{f}(x_i) = \frac{y_i + 1}{\sum_j (y_j + 1)}. \quad (59)$$

6.3.3 Model logistyczno-normalny Lenka

Jest to najbardziej podobny model do aksjomatycznego. Również jest modelem bayesowskim i również wykorzystuje transformację logistyczną (softmax) oraz MCMC do wnioskowania. Różnica jest w macierzy kowariancji i sposobie jej wyboru. Wyprowadziliśmy macierz kowariancji bezpośrednio z założonych aksjomatów. Spróbujemy więc zweryfikować, czy nasza funkcja kowariancji sprawdzi się zatem lepiej niż Lenka. Funkcja kowariancji w modelu Lenka wyraża się następującym wzorem:

$$k(x, y) = \sigma^2 \exp \left(- \left(\frac{d(x, y)}{l} \right)^2 \right).$$

Jeżeli aksjomaty odzwierciedlają to, jak zachowują się procesy w naturze, nasz model powinien sprawniej sobie radzić.

6.3.4 Przestrzenne modele sprzężone (Conjugate Spatial Models)

W tej rodzinie zawierają się trzy modele: Poissona i dwumianowy. Wszystkie z nich oparte są na sprzężonych rozkładach *a priori* oraz wykorzystują one priory referencyjne (Jeffreysa). Priory referencyjne Jeffreysa wyrażają się następującym wzorem dla macierzy informacji Fishera $\mathcal{I}(\theta)$ i dla wektora parametrów θ :

$$p(\theta) \propto \sqrt{\det \mathcal{I}(\theta)}. \quad (60)$$

Te modele będą stanowiły ostatni punkt odniesienia dla modelu autorskiego.

6.4 Procedury eksperymentalne i ewaluacja

6.4.1 Testy

Testy są przeprowadzane przez moduł **TestManager**. Uczciwość oraz powtarzalność eksperymentów są w nim zapewnione przez dwa mechanizmy.

Po pierwsze, dane po preprocessingu są przechowywane w pamięci. Gwarantuje to, że każdy z modeli otrzymuje identyczną siatkę jak pozostałe.


Kolejnym ważnym elementem jest to, że moduł ten przekazuje modelom jedynie próbkę N losowaną z rozkładu f_{true} i wartość metryk między punktami. Dzięki temu nie mamy wycieku danych, bo modele nigdy nie dostają bezpośrednio rozkładu f_{true} .

6.4.2 Scenariusz I: Pojedynczy test porównawczy

Pojedynczy test przeprowadziliśmy w następujący sposób. Ustalamy siatkę i losujemy próbkę obserwacji $N = 400$. Po przekazaniu modelom tych dwóch parametrów, każdy algorytm dokonał predykcji. Wyniki przedstawia Tabela 2, która pokazuje, że nasz model prezentuje lepsze wyniki od pozostałych podejść. Porównanie predykcji modelu autorskiego z prawdziwym rozkładem przedstawia Rysunek 3.

Tabela 2: Wyniki pojedynczego testu porównawczego dla $N = 400$ obserwacji.


Model	MSE	MAE	Korelacja Pearsona
Model Autorski	$1.3 \cdot 10^{-7}$	$2.86 \cdot 10^{-4}$	0.635
Model Lenka	$2.9 \cdot 10^{-7}$	$4.44 \cdot 10^{-4}$	0.50
Model Dirichleta	$4.67 \cdot 10^{-7}$	$1.98 \cdot 10^{-4}$	0.26
Spatial Smoothing	$1.85 \cdot 10^{-7}$	$3.50 \cdot 10^{-4}$	0.40
Model Dwumianowy Sprzężony	$2.28 \cdot 10^{-7}$	$3.86 \cdot 10^{-4}$	0.42
Model Poissona Sprzężony	$1.74 \cdot 10^{-7}$	$3.30 \cdot 10^{-4}$	0.45




Rysunek 3: Porównanie rozkładu prawdziwego (górna mapa) i estymowanego przez model autorski (dolna) dla $N = 400$ obserwacji.

6.4.3 Scenariusz II: Wpływ liczności próby

Następnie zbadamy, jak dla różnej liczby obserwacji zachowują się poszczególne modele. Definiujemy więc zbiór liczb obserwacji $N \in \{250, \dots, 100000\}$ i dla każdego elementu zbioru przeprowadzamy $k = 5$ powtórzeń. Wyniki przedstawiają wykresy (rys. 4) i (rys. 5). Widać na nich, że szczególnie w przypadku małej próbki, model wyprowadzony jest stabilny i najskuteczniejszy. Nierozważamy modelu Dirichleta, gdyż wypadał on daleko gorsze wyniki co zaburzałoby czytelność wyniki.




Rysunek 4: Zależność uśrednionych metryk od liczby obserwacji w skali log-log.



Rysunek 5: Rozkład wyników (boxploty) dla kolejnych wartości N .

6.4.4 Statystyczna weryfikacja istotności: test Nemenyi

Ostatnim etapem naszej weryfikacji jest test Friedmana z poprawką Nemenyiego. Przeprowadzamy go dla $N = 400$ dla 200 powtórzeń. Test wykazał, że model autorski ma istotnie statystycznie niższą średnią rangę niż pozostałe modele. Ponadto każda z różnic między modelami okazała się istotna statystycznie.



Rysunek 6: Diagram krytycznej różnicy (CD) dla testu Nemenyiego.

Każda para modeli różni się istotnie statystycznie pod względem wyników.

6.5 Omówienie wyników i wnioski

Przeprowadzone eksperymenty pokazały, że w zależności od ilości próbek, różne modele zachowują się najlepiej.

Gdy uwzględnimy małą liczbę obserwacji ($N \leq 10^3$), to nasz model aksjomatyczny osiąga najwyższą skuteczność, co potwierdziliśmy testem Nemenyiego.

Natomiast dla średniej liczności próbki ($N \approx 10^3 - 10^4$) modele sprzężone osiągają porównywalną (lub nieznacznie wyższą) skuteczność w stosunku do proponowanego rozwiązania.

Z kolei w sytuacji bardzo dużej próby, wygładzanie przestrzenne przewyższa wszystkie pozostałe modele pod względem wyników. Wynika to z faktu, że modele oparte na procesach gaussowskich osiągają barierę elastyczności.

Podsumowując: szczególnie dla małej ilości danych model aksjomatyczny okazuje się wartościowy. Takie deficyty danych są typowe dla geostatystyki, analiz środowiskowych i finansowych, ponieważ często gęste próbkowanie jest drogie lub niemożliwe. Jego przewaga wynika z geometrycznie uzasadnionego jądra kowariancji, które, jak pokazały testy, przekazuje nam znaczącą informację początkową.

7 Podsumowanie

W tej pracy podjęliśmy próbę opracowania (lub precyzyjniej: zamodelowania) bayesowskiej, nieparametrycznej estymacji gęstości prawdopodobieństwa na przestrzeniach metrycznych. Zgodnie z naszym celem zamiast dobierać funkcję kowariancji arbitralnie, wyznaczyliśmy ją bezpośrednio z założonych wcześniej aksjomatów.

W części teoretycznej pracy zamodelowaliśmy rozkład *a priori* procesem g , na który następnie nałożyliśmy trzy aksjomaty: addytywności geometrycznej i niezależności, ciągłości ścieżek, lokalności. Następnie przeprowadziliśmy formalny dowód (wykorzystujący m.in. twierdzenie Lévy’ego-Chinczyna oraz rzutowanie geometryczne w L^1). W tym dowodzie wykazaliśmy, że proces g spełnia aksjomaty wtedy i tylko wtedy, gdy jest procesem gaussowskim o konkretnej funkcji kowariancji. W ten sposób z aksjomatów wyprowadziliśmy konkretny rozkład *a priori*.

W sekcji empirycznej opisaliśmy praktyczny aspekt pracy i poddaliśmy ewaluacji nasz model. Rozpoczęliśmy od teoretycznego określenia, jak struktura powinna wyglądać, a następnie opisaliśmy jej implementację, w tym implementację naszego wyprowadzonego *Modelu Aksjomatycznego*. Wprowadziliśmy w niej również modele referencyjne oraz opisaliśmy procedurę testową, a następnie przedstawiliśmy wyniki.

Wyniki wykazały, że proponowany model bywa wysoce przydatny, szczególnie w przypadku małej liczby danych. Potwierdziliśmy tę tezę testem istotności Friedmana z poprawką Nemenyi (test post-hoc Nemenyi). To jednoznacznie udowodniło, że w przypadku rzadkich danych (np. $N \leq 10^3$) *Model Aksjomatyczny* wykazał się najwyższą skutecznością i najniższymi błędami estymacji.

Podsumowując, choć model zaproponowany posiada swoje słabsze strony, to wyprowadzona aksjomatycznie funkcja kowariancji sprawia, że dla małej liczby danych model nasz sprawdza się najlepiej. To jednoznacznie pokazuje użyteczność modelu. Praca nie tylko dostarcza spójny i działający model, ale również otwiera drogę do dalszych badań.

7.1 Dalsze drogi rozwoju

Choć wykazaliśmy użyteczność modelu i praca ta stanowi spójny i zamknięty fundament teoretyczny, to potencjał naszego rozwiązania jest dużo wyższy. Wskażmy dwa kluczowe kierunki, w których to można się spodziewać znacznej poprawy wyników modelu.

Po pierwsze podstawowym ograniczeniem naszego modelu, które można wskazać, jest aksjomat 1. Z tego powodu propozycją jest uogólnienie go parametrem gładkości. Drugim wariantem jest to, aby model na podstawie danych adaptował zadaną mu metrykę, tak aby odzwierciedlała szybkość zmian, a nie tylko odległość.

7.1.1 Uogólniony parametr gładkości i relaksacja niezależności przyrostów

Jak już podkreśliliśmy, pierwszym obiecującym kierunkiem rozwoju naszego modelu jest zmiana aksjomatu 1 (dotyczącego addytywności geometrycznej oraz niezależności przyrostów procesu na kierunkach ortogonalnych). W konsekwencji proces g staje się procesem, który choć dobrze radzi sobie w lokalnej rekonstrukcji gęstości, to z założenia nie ma możliwości wykrywania globalnych trendów przestrzennych.

Koncepcją jest więc wprowadzenie do naszego modelu jednego, globalnego parametru gładkości α . Miałby on pozwolić na identyfikację ewentualnych wyższych poziomów gładkości, co pozwoliłoby wykrywać nie tylko lokalne fluktuacje, ale również globalne trendy. Rząd gładkości jest bezpośrednio powiązany z potęgą wzrostu wariancji względem odległości. Parametr α kontrolowałby więc tę potęgę:

Dla funkcji o niskim rzędzie gładkości (klasa gładkości C^0) parametr przyjmowałby wartości bliskie $\alpha \approx 1$.

Dla funkcji o wyższym rzędzie gładkości, posiadających wiele ciągłych pochodnych (klasy C^1, C^2 i wyższe), wariancja rosłaby ze znacznie wyższą potęgą odległości (np. d^3 lub d^5). Funkcje takie w początkowej fazie rosną powoli i stabilnie, ale następnie bardzo mocno przyspieszają.

Jednakże obecnie bezpośrednia implementacja parametru α jest niemożliwa, a ogólne zadanie implementacji tego parametru jest wyjątkowo trudne. Bezpośrednie wstawienie parametru α jest niemożliwe i prowadzi do utraty poprawności formalnej modelu.

Po pierwsze, bezpośrednie wprowadzenie tego parametru niszczy założenia dowodowe. Nasza część teoretyczna i dowód w niej opierają się bezpośrednio na aksjomatyce addytywności. Wprowadzenie parametru α łamie go i odbiera możliwość wyciągania wniosków z twierdzeń udowodnionych w tej pracy.

Kolejną trudnością jest problem stworzenia spójnej rodziny rozkładów przestrzennych. W przeciwieństwie do obecnych założeń, parametr α spowodowałby, że rozkład *a priori* zależałby w dużym stopniu od wybrania punktu referencyjnego x_0 , gdyż taki parametr niszczyłby założenie stacjonarności przyrostów.

Podsumowując, choć problem ten wiąże się z wieloma trudnościami i wymaga rozwiązania wielu podproblemów, to jest on naturalnym kierunkiem rozwoju i stanowi perspektywę rozwoju, który może znacząco zoptymalizować model.

7.1.2 Adaptacyjna metryka przestrzeni i modelowanie anizotropii

Jak już wspomnieliśmy wcześniej, drugim potencjalnym kierunkiem rozwoju jest uelastycznienie metryki modelu. Choć metryka jest naszym początkowym źródłem informacji, to jest ona często ograniczona. Jak już zauważyliśmy wcześniej, zwiększenie odległości wzdłuż południków, a zmniejszenie wzdłuż równoleżników, lepiej by oddało naturę procesów geostatystycznych.

Koncepcja więc polega na tym, by zintegrować z modelem moduł, który analizowałby dane i adaptował zadaną początkowo metrykę w taki sposób, aby trafniej oddawała naturę zmian.

Jest to jednak wysoce problematyczne, ponieważ zbytnia elastyczność metryki zacierałaby wiedzę, która z niej płynie, a z kolei zbytnia sztywność (tak jak jest teraz) ogranicza nam elastyczność modelu, co widać szczególnie w przypadku dużej ilości danych.

Literatura

- [1] Prokhorov, Yu. V. (1956). Convergence of random processes and limit theorems in probability theory. *Theory of Probability & Its Applications*, 1(2), 157–214.
- [2] Billingsley, P. (1999). *Convergence of Probability Measures* (2. wydanie). John Wiley & Sons.
- [3] Talagrand, M. (2005). *The Generic Chaining: Upper and Lower Bounds of Stochastic Processes*. Springer.
- [4] Dudley, R. M. (1999). *Uniform Central Limit Theorems*. Cambridge University Press.
- [5] Krige, D. G. (1951). A statistical approach to some mine valuation problems on the Witwatersrand. *Journal of the Chemical, Metallurgical and Mining Society of South Africa*, 52(6), 119–139.
- [6] Matheron, G. (1963). Principles of geostatistics. *Economic Geology*, 58(8), 1246–1266.
- [7] Besag, J. (1974). Spatial interaction and the statistical analysis of lattice systems. *Journal of the Royal Statistical Society: Series B (Methodological)*, 36(2), 192–225.
- [8] Diggle, P. J., et al. “Model-Based Geostatistics.” *Journal of the Royal Statistical Society. Series C (Applied Statistics)*, vol. 47, no. 3, 1998, pp. 299–350. JSTOR, <http://www.jstor.org/stable/2986101>. Accessed 10 Aug. 2026.
- [9] Lenk, P. J. (1988). The logistic normal distribution for Bayesian, nonparametric, predictive densities. *Journal of the American Statistical Association*, 83(402), 509–516.
- [10] Møller, J., Syversveen, A. R., Waagepetersen, R. P. (1998). Log Gaussian Cox processes. *Scandinavian Journal of Statistics*, 25(3), 451–482.
- [11] Rue, H., Martino, S., Chopin, N. (2009). Approximate Bayesian inference for latent Gaussian models by using integrated nested Laplace approximations (with discussion). *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 71(2), 319–392.
- [12] Lindgren, F., Rue, H., Lindström, J. (2011). An explicit link between Gaussian fields and Gaussian Markov random fields using stochastic partial differential equations. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 73(4), 423–498.
- [13] Lévy, P. (1937). *Théorie de l’addition des variables aléatoires*. Gauthier-Villars, Paryż.
- [14] Billingsley, P. (1995). *Probability and Measure* (3. wydanie). John Wiley & Sons.
- [15] Kallenberg, O. (2002). *Foundations of Modern Probability* (2. wydanie). Springer.

- [16] Schoenberg, I. J. (1938). Metric spaces and completely monotone functions. *Annals of Mathematics*, 39(4), 811–841.
- [17] Sato, K. (1999). *Lévy Processes and Infinitely Divisible Distributions*. Cambridge University Press.
- [18] Krätschmer, V., Urusov, M. (2022). *A Kolmogorov-Chentsov type theorem on general metric spaces with applications to limit theorems for Banach-valued processes*. arXiv preprint arXiv:2107.13837.
- [19] Kaschner, K., Kesner-Reyes, K., Garilao, C., Segschneider, J., Rius-Barile, J., Rees, T., Froese, R. (2019). *AquaMaps: Predicted range maps for aquatic species*. World wide web electronic publication, www.aquamaps.org.
- [20] Vershynin, R. (2018). *High-Dimensional Probability: An Introduction with Applications in Data Science*. Cambridge University Press.
- [21] Metropolis, N., Rosenbluth, A. W., Rosenbluth, M. N., Teller, A. H., Teller, E. (1953). Equation of state calculations by fast computing machines. *The Journal of Chemical Physics*, 21(6), 1087–1092.
- [22] Hastings, W. K. (1970). Monte Carlo sampling methods using Markov chains and their applications. *Biometrika*, 57(1), 97–109.

Wykaz symboli i skrótów

Symbole matematyczne

S - przestrzeń metryczna (w eksperymentach: powierzchnia kuli)

$d(x, y)$ - metryka (funkcja odległości) na przestrzeni S

μ - miara bazowa na przestrzeni metrycznej

$f(x)$ - poszukiwana funkcja gęstości prawdopodobieństwa

$g(x)$ - proces stochastyczny (proces gaussowski logarytmicznych przyrostów gęstości)

$P, \mathbb{P}$ - miara probabilistyczna / prawdopodobieństwo

$\Omega, \mathcal{A}, \mathcal{F}$ - odpowiednio: przestrzeń zdarzeń elementarnych oraz σ -ciała

$K(x, y)$ - funkcja kowariancji procesu

Σ - macierz kowariancji

c - parametr zmienności geometrycznej (skala wariancji)

ℓ - hiperparametr skali przestrzennej (odwrotność c)

ν - miara skoków Lévy'ego

L^1 - przestrzeń wektorowa z normą miejską (taksówkową)

$\delta_J(x, y)$ - metryka cięcia

D - wymiar metryczny przestrzeni

$\mathcal{N}(\mu, \sigma^2)$ - rozkład normalny o wartości oczekiwanej μ i wariancji σ^2

$\mathbf{X}, X_i$ - wektor lub zbiór zaobserwowanych danych (próba)

N - liczba obserwacji (w eksperymentach)

Skróty

MCMC - *Markov Chain Monte Carlo* (metody oparte na łańcuchach Markowa)

INLA - *Integrated Nested Laplace Approximations*

SPDE - *Stochastic Partial Differential Equations* (stochastyczne równania różniczkowe cząstkowe)

IDW - *Inverse Distance Weighting* (metoda odwrotnych odległości)

IQR - *Interquartile Range* (rozstęp międzykwartyłowy)

MSE - *Mean Squared Error* (błąd średniokwadratowy)

MAE - *Mean Absolute Error* (średni błąd bezwzględny)

CD - *Critical Difference* (krytyczna różnica w teście Nemenyiego)

Spis rysunków

1	Rysunek hiper-równoległoscianu w L^1	25
2	Rysunek podziału kuli na sfery przy 3 punktach.	37
3	Porównanie rozkładu prawdziwego (górna mapa) i estymowanego przez model autorski (dolna) dla $N = 400$ obserwacji.	44
4	Zależność uśrednionych metryk od liczby obserwacji w skali log-log.	45
5	Rozkład wyników (boxploty) dla kolejnych wartości N	46
6	Diagram krytycznej różnicy (CD) dla testu Nemenyiego.	47

Spis tabel

1	Podsumowanie etapów przygotowania danych testowych.	41
2	Wyniki pojedynczego testu porównawczego dla $N = 400$ obserwacji. . . .	43